

Projet de Fin d'Etudes

Présenté pour obtenir le

Diplôme de Master En Sciences et Techniques

Génie du Littoral

Option : Dynamique côtière & Risques naturels

**Détection et prédiction des risques d'incendie de forêt par
télédétection et apprentissage automatique : cas de la
province de Chefchaouen**



Etudiant :

Fedjikh Ilyas

Encadrants :

Pr. EL TALIBI Hajar

Soutenu le XX/06/2025 devant le Jury composé de :

Pr. NOM Prénom, Président

Pr. NOM Prénom, Examineur

Pr. EL TALIBI Hajar, Encadrante Interne

Pr. DRISSI-EL-BOUZAIIDI Reda, Encadrant Externe

Universitaire : 2024/2025

PFE N° ... : GL/24/25

DEDICACES

Je remercie tout d'abord le bon ALLAH, À l'occasion de mon projet de fin d'études en master.

Je dédie ce travail à

A mes chers parents

Vous êtes une source de soutien qui n'a jamais cessé de m'encourager et de prier pour moi. Vous avez fait plus que ce que les parents peuvent faire pour que leurs enfants suivent le bon chemin dans leur vie et leurs études. Je te dédie ce travail en témoignage de mon profond amour. Qu'ALLAH les protège et leur réserve une longue vie pleine de bonheur et de santé longévité et bonheur.

A mes chers frères et sœur

Ayoub, achraf et yassmine qui sont toujours présents à tous mes examens avec un soutien moral, je vous souhaite un avenir plein de joie, de bonheur, de réussite et de sérénité.

À mes amis

Bilal Charki et Oussama Lagriha et Anas Et-tajani et Walid Lahmidi

Vous avez été une source d'inspiration et de soutien tout au long de ce projet de fin d'études. Votre amitié sincère, vos encouragements, vos conseils avisés et votre présence joyeuse ont été des éléments clés de ma réussite. Vous avez partagé les hauts et les bas, les moments de doute et les moments de triomphe. Je vous suis profondément reconnaissante pour votre amitié fidèle et votre soutien indéfectible

Merci du fond du cœur

REMERCIEMENT

Je remercie tout d'abord Dieu Tout-Puissant, qui m'a accordé la santé,

la force et la patience nécessaires pour mener à bien ce modeste travail.

J'exprime ma gratitude aux membres du jury pour leur présence,

leur lecture attentive de ce travail, ainsi que pour les remarques pertinentes formulées

lors de la soutenance contribuant à l'amélioration de mon projet.

J'adresse mes sincères remerciements et ma profonde reconnaissance à mon

encadrante, **Mme Hajar EL TALIBI,**

pour son accompagnement constant, son dévouement, ainsi que pour ses conseils

précieux tout au long de la réalisation de ce projet de fin d'études.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

RESUME

Les incendies de forêt constituent une menace croissante pour les écosystèmes méditerranéens et les populations locales. Cette étude propose un cadre prédictif combinant télédétection multi-temporelle et apprentissage automatique pour la détection et la prévision du risque d'incendie dans la province de Chefchaouen (Maroc). Les images Sentinel-2 et MODIS, enrichies par les variables climatiques d'ERA5-Land et des données topographiques, ont été traitées dans Google Earth Engine pour calculer des indices (NDVI, NDMI, NBR), l'altitude, la pente et le couvert terrestre, puis associées à des étiquettes d'incendie historiques. Le jeu de données équilibré exporté en CSV a servi à entraîner et à comparer trois classifieurs (Random Forest, Gradient Boosting, XGBoost) dans Google Colab. Les résultats montrent la supériorité de Random Forest en termes de performance prédictive. Des cartes de vulnérabilité spatialisées ont été générées pour guider les actions de prévention, en soulignant l'importance de la collaboration des acteurs locaux pour une gestion durable des risques.

Mots-clés : Télédétection, Apprentissage automatique, Risque d'incendie forestier, NDVI, NBR, Google Earth Engine, Chefchaouen.

ABSTRACT

Forest fires pose significant threats to Mediterranean ecosystems, public safety and local economies. This study develops predictive tools by integrating remote sensing and machine learning to detect and predict forest fire risk in the province of Chefchaouen, Morocco. Multi-temporal Sentinel-2 and MODIS imagery, together with ERA5-Land climatic variables and topographic data, were processed in Google Earth Engine to derive indices (NDVI, NDMI, NBR), elevation, slope, land cover and historical burned-area labels. The resulting balanced dataset was exported as CSV and used to train and evaluate Random Forest, Gradient Boosting and XGBoost classifiers in Google Colab. Comparative evaluation highlights Random Forest as the most effective model, demonstrating robust predictive performance for fire occurrence. Generated vulnerability maps deliver high-resolution spatial assessments to support targeted prevention and intervention strategies. The study underscores the importance of involving local stakeholders to ensure sustainable application and adoption. The proposed framework offers a scalable, cost-effective solution for enhancing forest fire management under changing climatic conditions.

Keywords : Remote sensing, Machine learning, Forest fire risk, NDVI, NBR, Google Earth Engine, Chefchaouen.

PREAMBULE

Le présent rapport s'inscrit dans le cadre d'un projet de fin d'études visant à développer des outils prédictifs pour la détection et la prévision des risques d'incendie forestier dans la province de Chefchaouen (Maroc). Face à l'augmentation de la fréquence et de l'intensité des feux, il est devenu crucial de coupler la puissance de la télédétection multi-temporelle et des techniques d'intelligence artificielle pour anticiper les départs de feu et optimiser les actions de prévention.

Après une revue du contexte régional et des enjeux environnementaux, le travail détaille la constitution d'un jeu de données intégrant indices spectraux, variables climatiques et topographiques, puis présente la mise en œuvre et la comparaison de classifieurs ML (Random Forest, Gradient Boosting, XGBoost). Les résultats offrent des cartes de vulnérabilité spatialement détaillées, en vue d'accompagner les décideurs et les acteurs locaux vers une gestion durable et proactive des risques d'incendie.

TABLE DES MATIERES

DEDICACES	i
REMERCIEMENT	ii
RESUME	iii
ABSTRACT	iv
PREAMBULE.....	v
TABLE DES MATIERES.....	vi
LISTE DES FIGURES	ix
LISTE DES TABLEAUX.....	xi
LISTE DES ABREVIATIONS	xii
GLOSSAIRE	xiii
I. INTRODUCTION GÉNÉRALE.....	1
I.1 Contexte et problématique	1
I.2 Importance de la gestion des incendies de forêt.....	1
I.3 L'impact environnemental, social et économique des incendies.....	2
I.4 Les limites des méthodes traditionnelles de détection et de prévision.....	3
I.5 L'apport du Machine Learning (ML) et de la télédétection dans la gestion des incendies	3
I.6 Objectifs.....	3
I.7 Contribution et apport scientifique.....	4
I.8 Organisation du mémoire	4
II. État de l'art sur la détection et la prédiction des incendies de forêt.....	6
II.1 Définition et classification des incendies de forêt.....	6
II.1.1 Définition des incendies de forêt.....	6
II.1.2 Types d'incendies et modes de propagation	6
II.1.3 Facteurs influençant la survenue et l'intensité des incendies.....	9
II.1.4 Causes naturelles.....	10
II.1.5 Causes humaines	11
II.1.6 Causes involontaires	11
II.1.7 Causes volontaires.....	12
II.2 Historique des incendies de forêt au Maroc	12
II.2.1 Évolution des incendies au fil des années	12
II.2.2 Zones les plus touchées et tendances récentes	17

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

II.3	Apport de la télédétection et du Machine Learning dans la gestion des incendies	19
II.3.1	Rôle de la télédétection dans la surveillance et la prévention	19
II.3.2	Algorithmes de Machine Learning appliqués à la prédiction des incendies ..	21
II.3.3	Travaux de recherche antérieurs sur la combinaison de ces technologies ...	23
II.4	Cadre réglementaire et impact des incendies de forêt	23
II.4.1	Législation et politiques de prévention des incendies.....	23
II.4.2	Impact environnemental des incendies	26
II.4.3	Effets socio-économiques.....	27
III.	PRESENTATION DE LA ZONE D'ETUDE.....	30
III.1	Présentation générale de la province de Chefchaouen	30
III.2	Caractéristiques climatiques et météorologiques.....	32
III.3	Végétation et couverture forestière	34
III.4	Facteurs de risque spécifiques à la région.....	35
III.4.1	Topographie accidentée.....	35
III.4.2	Activités humaines à haut risque	35
III.4.3	Conditions climatiques extrêmes.....	36
III.4.4	Faiblesse des dispositifs de surveillance	37
IV.	MATÉRIEL ET MÉTHODES.....	38
IV.1	Logiciel outils d'analyse	38
IV.1.1	Google Earth Engine (GEE).....	38
IV.1.2	Python et Jupyter Notebook	39
IV.1.3	Bibliothèques utilisées	40
IV.2	Méthodologie adoptée.....	44
IV.2.1	Prétraitement des données	44
IV.3	Données utilisées	44
IV.3.1	Données satellitaires	44
IV.3.2	Données météorologiques	48
IV.3.3	Données topographiques et anthropiques.....	51
IV.3.4	Implémentation des modèles de machine learning	53
IV.3.5	Évaluation des modèles.....	60
V.	RÉSULTATS ET DISCUSSION	62
V.1	Performance des modèles de prédiction.....	62
V.1.1	Random Forest.....	63

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

V.1.2	Gradient Boosting.....	65
V.1.3	XGBoost	66
V.2	Cartographie de la vulnérabilité	68
V.2.1	Modèle Random Forest.....	68
V.2.2	Modèle Gradient Boosting	69
V.2.3	Modèle XGBoost	70
V.3	Interprétation des résultats et complémentarité.....	71
V.4	Limites des modèles.....	72
VI.	CONCLUSION ET PERSPECTIVES.....	74
VI.1	Synthèse des contributions du projet.....	74
VI.2	Apport de la télédétection et du machine learning dans la prévention des incendies	75
VI.3	Limites et recommandations pour les travaux futurs.....	75
VI.4	Perspectives d'amélioration et d'intégration en temps réel	76
	Références.....	77

LISTE DES FIGURES

Figure 1 : Feux de sol.....	7
Figure 2 : Feux de surface.....	7
Figure 3 : Feux de cimes.....	8
Figure 4 : Les incendies de forêt dans le bassin méditerranéen).....	13
Figure 5 : Evolution des surfaces et nombre d'incendie entre 1960 et 2019.....	15
Figure 6 : répartition hebdomadaire des incendies de forêt.....	16
Figure 7 : Répartition mensuelle des incendies de forêt période 1997 et 2019.....	16
Figure 8 : Répartition horaire des incendies entre 1997 et 2019.....	17
Figure 9 : L'incendie de la forêt d'Achacha dans la province de Chefchaouen.....	18
Figure 10 : Localisation de la province de Chefchaouen.....	30
Figure 11 : Localisation et caractéristiques géographiques de la province de Chefchaouen.....	31
Figure 12 : Superficie forestière de la province de Chefchaouen par commune.....	31
Figure 13 : Diagramme ombrothermique Chefchaouen.....	32
Figure 14 : Courbe de température Chefchaouen.....	33
Figure 15 : représente brûlage des chaumes.....	35
Figure 16 : représente la fabrication artisanale de charbon de bois.....	36
Figure 17 : Exemple de combustion illégale de déchets en milieu naturel.....	36
Figure 18 : Interface de la plateforme Google Earth Engine utilisée pour l'extraction et le traitement des données géospatiales.....	38
Figure 19 : Interface de Google Colab utilisée pour l'analyse des données et l'entraînement des modèles de machine learning.....	39
Figure 20 : Schéma global du processus de prédiction des incendies de forêt.....	44

Figure 21 : Délimitation de la zone d'étude : province de Chefchaouen dans Google Earth Engine.....	45
Figure 22 : Visualisation et calcul des indices de végétation (NDVI, NDMI, NBR) dans la région de Chefchaouen via Google Earth Engine.....	46
Figure 23 : Carte de l'indice de végétation NDVI pour la province de Chefchaouen à partir des images Sentinel-2 (année 2023).....	46
Figure 24 : Carte de l'indice d'humidité NDMI pour la province de Chefchaouen à partir des images Sentinel-2 (année 2023).....	47
Figure 25 : Carte de l'indice NBR pour la province de Chefchaouen à partir des images.....	47
Figure 26 : Carte de la température moyenne annuelle en 2023 dans la province de Chefchaouen, issue des données MODIS.....	48
Figure 27 : Interface de traitement et de visualisation dans Google Earth Engine (GEE) montrant le script d'analyse des précipitations mensuelles à Chefchaouen entre 2018 et 2023.....	49
Figure 28 : Variation mensuelle des précipitations moyennes (en mm) dans la province de Chefchaouen de 2018 à 2023, obtenue à partir des données ERA5-Land agrégées via GEE.....	49
Figure 29 : Carte binaire des zones brûlées dans la province de Chefchaouen entre 2010 et 2023 à partir des données MODIS MCD64A1.....	50
Figure 30 : Carte de l'altitude dans la province de Chefchaouen à partir du Modèle Numérique de Terrain (SRTM).....	51
Figure 31 : Carte de la pente en degrés dans la province de Chefchaouen à partir du Modèle Numérique de Terrain (SRTM).....	52
Figure 32 : Carte d'occupation du sol dans la province de Chefchaouen selon les données ESA WorldCover 2021.....	52
Figure 33 : La dataset utilisé pour trainer les modèle ML	54
Figure 34 : Entraînement du modèle Random Forest pour la prédiction des incendies de forêt à partir de données géospatiales et environnementales.	55
Figure 35 : Entraînement du modèle Gradient Boosting pour la prédiction des incendies de forêt à partir de données géospatiales et environnementales.	57
Figure 36 : Entraînement du modèle XGBoost pour la prédiction des incendies de forêt à partir de données géospatiales et environnementales.	59
Figure 37 : Matrice de confusion du modèle Random Forest appliqué à la prédiction des risques d'incendie dans la province de Chefchaouen.	64
Figure 38 : Courbe ROC du modèle Random Forest pour la prédiction des risques d'incendie dans la province de Chefchaouen.....	64

Figure 39 : Matrice de confusion du modèle Gradient Boosting pour la prédiction des risques d'incendie dans la province de Chefchaouen.	65
Figure 40 : Courbe ROC du modèle Gradient Boosting pour la prédiction des risques d'incendie dans la province de Chefchaouen.	66
Figure 41 : Matrice de confusion du modèle XGBoost pour la prédiction des risques d'incendie dans la province de Chefchaouen.	67
Figure 42 : Courbe ROC du modèle XGBoost pour la prédiction des risques d'incendie dans la province de Chefchaouen.	67
Figure 43 : Carte de vulnérabilité aux incendies dans la province de Chefchaouen selon le modèle Random Forest.	68
Figure 44: Carte de vulnérabilité aux incendies dans la province de Chefchaouen selon le modèle Gradient Boosting.	69
Figure 45 : Carte de vulnérabilité aux incendies dans la province de Chefchaouen selon le modèle XGBoost.	70
Figure 46 : Courbe ROC comparative des modèles Random Forest, Gradient Boosting et XGBoost pour la prédiction des risques d'incendie dans la province deChefchaouen.....	71

LISTE DES TABLEAUX

Tableau 1 : Climat de Chefchaouen 1991-2021.....	33
Tableau 2 : Taux du couvert forestier dans la région de Chefchaouen.....	34
Tableau 3: Tableau3: Description des données exploitées dans le projet.....	45

LISTE DES ABREVIATIONS

AUC	Aire sous la courbe (Area Under the Curve)
AI / IA	Intelligence artificielle
CSV	Comma-Separated Values (format de fichier tabulaire)
ERA5	ECMWF Reanalysis v5 Land (réanalyse climatique)
GEE	Google Earth Engine
GB	Gradient Boosting
LST	Land Surface Temperature (température de surface terrestre)
MCD64A1	MODIS Burned Area Product (produit de détection des zones brûlées)
ML	Machine Learning
MODIS	Moderate Resolution Imaging Spectroradiometer
MNT	Modèle numérique de terrain
NDMI	Normalized Difference Moisture Index
NDVI	Normalized Difference Vegetation Index
NBR	Normalized Burn Ratio
PFE	Projet de fin d'étude
RF	Random Forest
ROC	Receiver Operating Characteristic
SRTM	Shuttle Radar Topography Mission
XGB	eXtreme Gradient Boosting

GLOSSAIRE

Apprentissage supervisé	Méthode de machine learning où le modèle est entraîné à partir d'exemples étiquetés (par ex. « feu » vs « non-feu »).
Classification binaire	Tâche de ML visant à répartir chaque pixel en deux classes : feu (1) ou non-feu (0).
Courbe ROC	Graphique représentant la sensibilité (taux de vrais positifs) en fonction de la spécificité (1 – taux de faux positifs) selon différents seuils.
Hyperparamètre	Paramètre externe au modèle (profondeur d'arbre, taux d'apprentissage, etc.) fixé avant l'entraînement et influant sur ses performances.
Indice de végétation normalisé (NDVI)	Calcul $((\text{NIR} - \text{Rouge})/(\text{NIR} + \text{Rouge}))$ évaluant la biomasse et la densité végétale via les bandes proche-infrarouge et rouge.
Indice d'humidité normalisé (NDMI)	Calcul $((\text{NIR} - \text{SWIR})/(\text{NIR} + \text{SWIR}))$ mesurant l'humidité du couvert végétal à partir des bandes proche-infrarouge et infrarouge à ondes courtes.
Matrice de confusion	Tableau 2×2 détaillant le nombre de vrais positifs, faux positifs, vrais négatifs et faux négatifs d'un modèle de classification.
Modélisation des risques en temps réel	Intégration continue de données (météo, indices, historique incendies) pour estimer à tout moment la probabilité d'un départ de feu.
Pixel	Plus petite unité d'une image satellite, représentant une surface au sol (ex. 10 m × 10 m pour Sentinel-2).
Résolution spatiale	Dimension au sol couverte par un pixel ; plus elle est fine, plus les détails spatiaux sont précis.
Télédétection multi-temporelle	Acquisition et comparaison d'images satellites à différentes dates pour suivre l'évolution de la végétation et détecter les zones sensibles au feu.
Validation croisée	Méthode d'évaluation où le jeu de données est découpé en plusieurs sous-ensembles pour entraîner et tester le modèle de façon répétée.
Zone d'étude	Périmètre géographique analysé dans ce projet : la province de Chefchaouen.

I. INTRODUCTION GÉNÉRALE

I.1 Contexte et problématique

Les incendies de forêt représentent un phénomène naturel aux impacts particulièrement destructeurs, dont la fréquence et la gravité connaissent une augmentation constante à l'échelle mondiale. Cette évolution est largement attribuée aux effets du changement climatique, caractérisé par une élévation des températures, des périodes de sécheresse prolongées et des précipitations de plus en plus irrégulières [1].

Par ailleurs, l'intensification de l'urbanisation ainsi que les activités humaines telles que l'agriculture, le développement touristique ou l'usage non maîtrisé du feu contribuent fortement à accentuer les risques d'éclosion et de propagation des incendies [2].

Au Maroc, les écosystèmes forestiers en particulier ceux de la région de Chefchaouen présentent une vulnérabilité accrue aux incendies en raison de leur densité végétale, des conditions climatiques extrêmes et de la forte pression exercée par les activités humaines [3]. La rapidité de propagation des feux, combinée à la difficulté d'accès dans les zones montagneuses, rend indispensable la mise en place de dispositifs performants de détection et de prédiction, capables de prévenir efficacement ces phénomènes destructeurs.

I.2 Importance de la gestion des incendies de forêt

Une gestion proactive et intelligente des incendies s'avère indispensable pour préserver la biodiversité, protéger les infrastructures humaines et assurer la sécurité des populations. Au Maroc, les forêts occupent environ 12 % de la superficie nationale et jouent un rôle fondamental dans la régulation du climat, la conservation des sols ainsi que dans le développement socio-économique des zones rurales [4]. En l'absence de stratégies efficaces de détection précoce et de prédiction des risques, ces écosystèmes restent exposés à des pertes écologiques majeures et à des répercussions économiques considérables. Le renforcement des capacités de surveillance et d'intervention rapide

constitue dès lors un pilier essentiel pour garantir une gestion durable et résiliente des forêts marocaines.

I.3 L'impact environnemental, social et économique des incendies

Impacts environnementaux : Les incendies de forêt engendrent des conséquences environnementales significatives. Ils entraînent la destruction des habitats naturels, mettant en péril de nombreuses espèces et réduisant la biodiversité. La disparition du couvert végétal accentue l'érosion des sols, altérant ainsi la stabilité des écosystèmes et compromettant leur capacité de résilience face aux perturbations. Par ailleurs, ces incendies libèrent d'importantes quantités de gaz à effet de serre, contribuant ainsi au réchauffement climatique [5].

Impacts sociaux : Les incendies de forêt peuvent provoquer le déplacement forcé des populations résidant à proximité des zones touchées, menaçant directement leur sécurité et, dans certains cas, entraînant des pertes humaines. Les fumées et les particules fines libérées dans l'atmosphère détériorent la qualité de l'air, ce qui engendre des troubles respiratoires, notamment chez les personnes vulnérables telles que les enfants, les personnes âgées ou les individus souffrant de pathologies chroniques. Ces effets compromettent durablement la santé publique et le bien-être des communautés exposées [6].

Impacts économiques : Les incendies de forêt causent la perte de ressources naturelles précieuses, notamment le bois, la faune et les plantes médicinales, représentant ainsi un appauvrissement direct du patrimoine naturel. Les opérations de lutte contre les incendies, qui mobilisent d'importants moyens humains, techniques et aériens, génèrent des coûts considérables. De plus, la dégradation des paysages affecte négativement l'attractivité touristique des régions touchées, entraînant une baisse de fréquentation et de revenus. Enfin, la destruction du capital forestier se traduit par une perte importante de revenus pour les filières locales, compromettant l'économie des zones rurales dépendantes de ces ressources [7].

I.4 Les limites des méthodes traditionnelles de détection et de prévision

Les systèmes traditionnels de gestion des incendies s'appuient principalement sur des dispositifs tels que les tours de guet, les patrouilles terrestres ou l'interprétation manuelle d'images satellitaires. Bien que ces méthodes aient démontré leur utilité dans certains contextes, elles présentent de nombreuses limites : une détection souvent tardive, une couverture spatiale restreinte et une forte dépendance à l'interprétation humaine, source de subjectivité [8].

Par ailleurs, ces approches sont rarement capables d'anticiper les conditions propices à l'émergence de feux, ce qui réduit considérablement leur efficacité dans une optique de prévention proactive.

I.5 L'apport du Machine Learning (ML) et de la télédétection dans la gestion des incendies

L'intégration des techniques de télédétection et des algorithmes de Machine Learning constitue une avancée majeure dans la gestion des incendies de forêt. Grâce aux images satellites, il est possible d'accéder à des données environnementales à haute résolution spatiale et temporelle, incluant des variables clés telles que la couverture végétale, la température, l'humidité ou encore l'indice de sécheresse [9].

Le Machine Learning, de son côté, permet d'analyser ces vastes volumes de données en détectant des schémas complexes et en estimant la probabilité d'apparition d'un incendie en fonction de multiples facteurs. Cette approche automatisée, adaptative et capable de fonctionner en temps quasi réel améliore considérablement la capacité de prévention et facilite des interventions plus rapides et plus ciblées [10].

I.6 Objectifs

L'objectif principal de ce travail est de concevoir un système permettant la détection et la prédiction des risques d'incendie de forêt en s'appuyant sur l'analyse d'images satellitaires couplée à des techniques de Machine Learning.

Plus précisément, cette étude vise à :

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

- Acquérir des données pertinentes issues de multiples sources à l'aide de la plateforme Google Earth Engine ;
- Effectuer un prétraitement de ces données afin d'en extraire des variables explicatives représentatives des conditions favorables aux incendies ;
- Développer et entraîner des modèles d'apprentissage automatique pour identifier et évaluer les zones à risque ;
- Produire des cartes spatio-temporelles dynamiques facilitant la visualisation et l'interprétation des niveaux de risque sur le territoire étudié.

I.7 Contribution et apport scientifique

Ce travail s'inscrit dans la continuité des recherches en intelligence artificielle appliquées aux enjeux environnementaux, en particulier à la gestion des risques naturels. Il propose une démarche méthodologique intégrée, combinant l'exploitation de données satellitaires en libre accès avec l'application d'algorithmes prédictifs performants mais accessibles, favorisant ainsi la transparence, la reproductibilité scientifique et la répliquabilité dans d'autres contextes.

L'objectif principal de cette étude est de contribuer au renforcement des capacités locales en matière de prévention des incendies de forêt, notamment dans des zones particulièrement exposées comme la province de Chefchaouen. À travers le développement d'un outil d'aide à la décision, ce travail vise à appuyer la mise en place de politiques de gestion forestière durable et résiliente face aux changements climatiques.

I.8 Organisation du mémoire

La structure de ce mémoire s'articule autour des cinq chapitres suivants :

- Le premier chapitre propose un état de l'art portant sur les incendies de forêt, en abordant les principaux facteurs de risque ainsi que les méthodes actuelles de détection et de prédiction.
- Le deuxième chapitre décrit la zone d'étude, en mettant en lumière ses caractéristiques environnementales, climatiques et socio-économiques.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

- Le troisième chapitre détaille l'ensemble des données exploitées ainsi que la méthodologie adoptée pour le prétraitement, l'extraction des variables et la modélisation.
- Le quatrième chapitre présente les résultats issus des expérimentations, les cartes spatio-temporelles de risques générées, ainsi que l'évaluation des performances des modèles prédictifs.
- Enfin, la conclusion générale synthétise les principaux apports de l'étude et ouvre sur des perspectives d'amélioration et d'approfondissement pour de futurs travaux de recherche.

II. État de l'art sur la détection et la prédiction des incendies de forêt

II.1 Définition et classification des incendies de forêt

II.1.1 Définition des incendies de forêt

Un incendie de forêt se définit comme un feu non contrôlé qui se propage dans des formations végétales naturelles telles que les forêts, les broussailles, les savanes ou les garrigues [11].

Ces incendies peuvent être d'origine naturelle comme les éclairs ou la combustion spontanée ou résulter d'activités humaines, notamment les brûlages agricoles, les imprudences ou les actes de malveillance [2].

Leur caractère imprévisible, associé à la fréquence croissante des conditions climatiques extrêmes, rend leur détection, leur surveillance et leur gestion particulièrement complexes [1].

II.1.2 Types d'incendies et modes de propagation

On distingue généralement trois types d'incendies :

-  Les feux de sol qui brûlent la litière, les herbes, les broussailles.
-  Les feux de surface qui se propagent dans la canopée des arbres.
-  Les feux de cimes plus rares, qui progressent dans les racines ou la tourbe [11].

II.1.2.1 Feux de sol

Les feux de sol désignent les incendies qui affectent la matière organique présente dans la litière, l'humus ou les tourbières. Il s'agit de feux à incandescence, caractérisés par une propagation lente due à la faible disponibilité en oxygène et à la transmission de la chaleur principalement par conduction. Bien qu'ils soient généralement peu spectaculaires en surface, ces feux peuvent s'avérer extrêmement destructeurs en endommageant les structures souterraines des végétaux (voir figure 1). Leur capacité à couvrir en profondeur pendant de longues périodes rend leur extinction particulièrement difficile. Ce type d'incendie reste relativement rare dans les zones à climat méditerranéen [11].



Figure 1 : Feux de sol [11].

II.1.2.2 Les feux de surface

Les feux de surface sont les plus fréquents. Ils affectent les strates basses de la végétation, notamment la partie supérieure de la litière, la végétation herbacée ainsi que les arbustes et ligneux bas (voir figure 2). Ce type de feu se propage rapidement, principalement par rayonnement et convection, générant d'importantes flammes et une chaleur intense. Il touche particulièrement les formations végétales comme la garrigue ou les landes.

Par ailleurs, les feux de surface peuvent provoquer l'embrasement de la canopée en progressant de branche en branche, entraînant ainsi des feux de cime [11].




Figure 2 : Feux de surface [11].

II.1.2.3 Les feux de cimes

Les feux de cime se caractérisent par la combustion des parties supérieures des arbres, en particulier les couronnes, libérant ainsi d'importantes quantités d'énergie cinétique (voir figure 3). Ils peuvent se propager directement d'une cime à l'autre, ou bien se déclencher à partir d'un feu de surface lorsque la chaleur émise est suffisamment intense pour atteindre la canopée. Ces incendies sont généralement spectaculaires et particulièrement violents, produisant de grandes quantités de chaleur et de flammes. Le vent fort et les conditions de sécheresse favorisent une propagation rapide, rendant les opérations de lutte extrêmement complexes pour les services d'intervention [11].




Figure 3 : Feux de cimes [11].

Les modes de propagation des incendies dépendent d'un ensemble de facteurs environnementaux et topographiques, notamment la nature du combustible, la vitesse et la direction du vent, l'humidité de l'air, la pente du terrain ainsi que la température ambiante. Parmi ces éléments, le vent joue un rôle particulièrement déterminant, car il contribue à l'accélération du front de feu et à l'élargissement de la zone sinistrée [4], [6].

II.1.3 Facteurs influençant la survenue et l'intensité des incendies

II.1.3.1 Climatiques

Les conditions climatiques jouent un rôle fondamental dans le déclenchement et la propagation des incendies de forêt. Des températures élevées, combinées à des périodes prolongées de sécheresse et à un déficit de précipitations, entraînent un assèchement important de la végétation et des sols. Cette situation favorise la formation d'un environnement hautement inflammable, propice à l'initiation et à la rapide propagation des feux [5].

II.1.3.2 Topographiques

Les caractéristiques topographiques influencent de manière significative le comportement des incendies de forêt. Des facteurs tels que l'altitude, l'orientation du terrain par rapport à l'exposition solaire et l'inclinaison des pentes jouent un rôle déterminant dans la dynamique de propagation du feu. Par exemple, les fortes pentes facilitent la montée rapide des flammes en raison du transfert vertical de chaleur, tandis qu'une orientation vers le sud, plus exposée au rayonnement solaire, accélère le dessèchement de la végétation, augmentant ainsi le risque d'embrasement [6].

II.1.3.3 Anthropiques

Les activités humaines constituent un facteur déterminant dans le déclenchement et l'aggravation des incendies de forêt. La proximité des zones habitées avec les milieux forestiers accroît le risque d'incendies accidentels ou volontaires, du fait de la présence humaine fréquente. Certaines pratiques agricoles, telles que le brûlis, l'abandon des terres ou l'extension non maîtrisée des cultures, favorisent également l'émergence de feux incontrôlés. Par ailleurs, l'existence de réseaux électriques traversant les forêts représente une source potentielle d'étincelles, particulièrement en période de forte chaleur et de sécheresse [7].

La complexité de ces phénomènes réside dans l'interdépendance de multiples facteurs. En effet, la survenue et l'intensité des incendies résultent d'une combinaison de conditions climatiques (températures élevées, faible humidité, vents soutenus),

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

topographiques (pentes marquées, expositions sud) et biologiques (type de végétation, teneur en eau des plantes) [19].

Les activités anthropiques, telles que l'agriculture ou l'urbanisation en bordure de forêts, viennent renforcer ces risques [20].

Face à cette complexité, l'analyse des incendies nécessite des approches avancées et intégrées, capables de prendre en compte les multiples dimensions spatiales, temporelles et environnementales [5].

II.1.3.4 Les causes des feux de forêt

Les causes des incendies de forêt varient d'un pays à l'autre et évoluent au fil du temps, ce qui rend leur identification précise particulièrement complexe. Néanmoins, l'influence humaine demeure la principale origine de ces feux à l'échelle mondiale. On estime que près de 90 % des incendies de forêt sont directement liés à des activités anthropiques, qu'il s'agisse d'accidents, de pratiques agricoles inadaptées, de déforestation ou encore d'actes de malveillance tels que les incendies criminels.

II.1.4 Causes naturelles

La végétation ne pouvant s'enflammer spontanément, même en période de sécheresse extrême, les causes naturelles des incendies de forêt restent rares, notamment dans les pays du Bassin Méditerranéen. La foudre constitue l'unique cause naturelle significative identifiée dans cette région. D'après le guide PPR (2000), elle ne serait responsable que de 4 à 7 % des départs de feux, généralement localisés au cœur des massifs forestiers durant la saison estivale.

En revanche, dans d'autres régions du monde comme la forêt boréale, les orages secs sont fréquents et représentent une cause majeure d'incendies, notamment aux États-Unis et au Canada, où ils provoquent chaque année d'importants dégâts.

Les éruptions volcaniques peuvent également déclencher des incendies de forêt, bien que ce phénomène reste exceptionnel dans le contexte méditerranéen.

II.1.5 Causes humaines

Le contrôle des causes humaines des incendies de forêt devient de plus en plus complexe, notamment en raison de l'intensification des activités humaines à proximité des espaces naturels. Sur le plan statistique, ces causes représentent la grande majorité des déclenchements d'incendies.

Elles se répartissent généralement en deux catégories : les causes involontaires, telles que les imprudences, les défaillances techniques ou les accidents liés aux activités agricoles et récréatives ; et les causes volontaires, résultant d'actes délibérés comme le brûlage non contrôlé ou les incendies criminels.

II.1.6 Causes involontaires

Parmi les causes identifiées, les incendies involontaires, dus à des négligences ou à des accidents, sont les plus fréquents dans la majorité des pays. Une exception notable est la Turquie, où les mises à feu délibérées semblent prédominantes.

La plupart des foyers d'incendie apparaissent aux interfaces entre les milieux naturels et les zones urbanisées, où la pression humaine est plus forte. Les populations urbaines, souvent éloignées des réalités forestières, sous-estiment le danger que représentent les incendies, même en période estivale critique. Beaucoup de citoyens ne perçoivent pas les feux de forêt comme une menace directe.

Les accidents et imprudences constituent ainsi les causes les plus répandues des incendies de forêt. Ces causes varient selon les pays, mais on distingue généralement deux catégories :

- celles liées à des installations fixes, comme les lignes électriques, les décharges ou les infrastructures mal entretenues ;
- et celles liées directement aux activités humaines, telles que les feux mal maîtrisés des charbonniers, les brûlages agricoles, les mégots jetés, les feux de camp ou encore les feux allumés par les bergers.

Il est courant d'observer des départs de feu sur les terre-pleins centraux des autoroutes, souvent dus à des jets de cigarettes ou à des étincelles mécaniques. Globalement, ces feux

involontaires semblent étroitement liés aux activités agricoles et forestières, soulignant l'importance d'une sensibilisation accrue dans ces secteurs.

II.1.7 Causes volontaires

Les incendies volontaires sont souvent parmi les plus destructeurs, car l'individu à leur origine choisit généralement un moment et un lieu particulièrement propices à la propagation du feu en ciblant des zones très inflammables et en agissant lors de conditions climatiques extrêmes, comme les fortes chaleurs.

Parmi ces auteurs, on retrouve des pyromanes, qui déclenchent des feux par plaisir, impulsion ou recherche de sensation. La pyromanie peut revêtir différentes formes, allant de comportements pathologiques à des actes délibérés mais rationnels, selon le niveau de conscience et de responsabilité de l'individu.

Les feux volontaires peuvent également être motivés par des raisons économiques ou politiques. Certains incendies sont provoqués dans le but de faire chuter le prix du bois sur le marché, ou par vengeance à la suite de conflits liés aux droits de chasse, à la propriété foncière, ou à la gestion forestière. Dans d'autres cas, des feux sont allumés pour faire fuir des animaux nuisibles ou pour influencer certaines décisions d'aménagement du territoire.

II.2 Historique des incendies de forêt au Maroc

II.2.1 Évolution des incendies au fil des années

Pour l'année 2017, la superficie moyenne parcourue par incendie au Maroc, entre janvier et le 30 septembre, s'élève à 6,3 hectares. Par ailleurs, 73 % des surfaces touchées sont constituées de strate herbacée, d'alfa et d'essences secondaires, ce qui reflète l'efficacité relative des dispositifs de surveillance, d'alerte précoce et d'intervention – tant terrestres qu'aériens – mis en place [8].

À l'échelle du bassin méditerranéen, la saison des incendies de 2017 a été particulièrement intense. Selon les données fournies par le Système Européen d'Informations sur les Feux de Forêts (EFFIS), les superficies forestières brûlées s'élèvent à 213 986 hectares au Portugal, 81 929 hectares en Espagne et 13 574 hectares en France

Les causes structurelles des incendies de forêt dans la région méditerranéenne sont désormais bien établies. Elles sont principalement liées à la sécheresse estivale, aux vents caractéristiques de ce climat, à une végétation particulièrement inflammable en raison de sa structure et de sa composition floristique, au relief accidenté, ainsi qu'au contexte socio-économique, marqué notamment par l'abandon des terres agricoles et l'embroussaillage, notamment sur la rive nord de la Méditerranée.

Chaque année, environ 1 % de la forêt méditerranéenne est ravagée par les flammes, ce qui représente près de 400 000 hectares brûlés. Ces incendies entraînent, en plus des pertes humaines, d'importants dégâts écologiques et économiques. Contrairement à d'autres régions du monde, où les feux d'origine naturelle (notamment la foudre) sont prédominants, les incendies en Méditerranée sont dans 95 % des cas d'origine humaine, qu'il s'agisse de négligences ou d'actes criminels.




Figure 4 : Les incendies de forêt dans le bassin méditerranéen (source : DEF-2019).

Au regard de ces données, la situation du Maroc se distingue nettement de celle de ses voisins méditerranéens. Si les causes exactes de cet écart ne sont pas encore clairement établies, plusieurs facteurs sont susceptibles de l'expliquer.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Parmi eux figurent la fréquence des actes de mise à feu, la nature et la structure des peuplements forestiers, ainsi que l'efficacité relative des politiques nationales de prévention et de lutte contre les incendies.

Un autre facteur explicatif pourrait être lié à l'intensité de l'activité sylvopastorale dans certaines régions, qui contribue à réduire significativement la biomasse combustible au sol, limitant ainsi le risque de propagation du feu. Il convient toutefois de noter que le risque moyen annuel présente une forte variabilité régionale à l'intérieur même du territoire marocain.

Il est important de rappeler que le programme d'action de prévention et de lutte contre les incendies de forêts, mis en œuvre au cours de l'année 2017, s'est articulé autour de trois composantes principales :

- Le renforcement de la prévention, notamment par des actions de sensibilisation du grand public et par la réalisation de travaux d'équipement et de traitement des forêts. La communication autour des risques et des impacts des incendies de forêt, diffusée à travers divers supports médiatiques, constitue une mesure essentielle, sachant que la quasi-totalité des départs de feu est liée à l'activité humaine, qu'il s'agisse d'imprudence ou d'actes volontaires. Il est d'ailleurs important de souligner que 99 % des incendies sont d'origine anthropique.
- La détection et l'alerte précoce, à travers la mise en place d'un dispositif structuré incluant la cartographie prévisionnelle des zones à risque, le prépositionnement stratégique des équipes d'intervention, ainsi que l'installation d'un réseau de guetteurs et de patrouilles terrestres dans les zones forestières les plus sensibles. Ce système vise à anticiper les départs de feu et à assurer une réaction rapide en cas d'incendie.
- L'opérationnalisation du dispositif d'intervention, comprenant la mobilisation coordonnée des moyens terrestres et aériens pour la lutte contre les incendies de forêt. Cette composante vise à garantir une réactivité maximale face aux départs de feu, en assurant une intervention rapide, ciblée et efficace sur les foyers détectés.

La stratégie nationale d'intervention contre les incendies de forêt repose sur un système gradué à trois niveaux, permettant une réponse progressive en fonction de la gravité de la situation.

- Le premier niveau s'appuie sur une intervention rapide dès le départ du feu, assurée par les services du Haut-Commissariat aux Eaux et Forêts et à la Lutte Contre la Désertification (HCEFLCD), avec l'appui de véhicules de première intervention (VPI) et des unités de la Protection Civile.
- Le deuxième niveau est activé lorsque la situation dépasse les capacités du premier échelon. Il consiste en la mobilisation d'avions bombardiers d'eau (notamment des Canadairs d'une capacité de 6 tonnes) des Forces Royales Air, ainsi que l'intervention d'équipes au sol des Forces Auxiliaires.
- En cas de propagation majeure ou de situation critique, le troisième niveau prévoit l'engagement des Forces Armées Royales et des avions de la Gendarmerie Royale, afin de contenir l'incendie, protéger les populations, sécuriser les infrastructures et préserver les zones sensibles [8].

En dépit de ces résultats positifs, le dispositif estival de veille et d'intervention reste à son niveau maximal de mobilisation et d'alerte jusqu'aux premières pluies [8].




Figure 5 : Evolution des surfaces et nombre d'incendie entre 1960 et 2019.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 6 : répartition hebdomadaire des incendies de forêt (source DEF).




Figure 7 : Répartition mensuelle des incendies de forêt période 1997 et 2019.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 8 : Répartition horaire des incendies entre 1997 et 2019 (source DEF).

II.2.2 Zones les plus touchées et tendances récentes

Les régions du nord du Maroc, notamment Chefchaouen, Larache et Tétouan, figurent parmi les zones les plus exposées aux incendies de forêt. Cette vulnérabilité s'explique par une forte densité forestière couplée à une topographie montagneuse et difficile d'accès, qui complique les opérations de lutte [8].

L'année 2022 a été marquée par un événement particulièrement dramatique à Chefchaouen, où plus de 9 000 hectares de forêts ont été ravagés par les flammes. Cet épisode a constitué un véritable tournant dans la politique nationale de prévention, soulignant l'urgence de renforcer les dispositifs de surveillance et d'intervention dans cette région [8].

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection



Figure 9 : L'incendie de la forêt d'Achacha dans la province de Chefchaouen [8].

Selon les déclarations de M. Hajjaji à la presse, environ la moitié de la végétation détruite par les incendies dans la forêt du Parc national de Talassemrane était constituée d'espèces arborées, notamment le Pin maritime, le Pin d'Alep, le Genévrier et le Chêne vert. L'autre moitié correspondait principalement à une végétation secondaire herbacée, soulignant la diversité des formations végétales touchées par les flammes [8].

Par ailleurs, selon le responsable, les efforts des équipes d'intervention, tant aériennes que terrestres, se poursuivent activement afin de contenir les foyers d'incendie. Toutefois, la topographie accidentée de la région constitue un obstacle majeur, entravant l'accès des engins et des camions de pompiers aux zones sinistrées, ce qui rend les opérations de lutte contre le feu particulièrement complexes [8].

Les tendances observées révèlent également une concentration accrue des incendies de forêt entre les mois de juin et septembre, une période marquée par des pics de chaleur et une diminution critique de l'humidité, créant ainsi des conditions particulièrement favorables à l'éclosion et à la propagation des feux.

II.3 Apport de la télédétection et du Machine Learning dans la gestion des incendies

II.3.1 Rôle de la télédétection dans la surveillance et la prévention

La télédétection occupe aujourd'hui une place essentielle dans les dispositifs de surveillance, de détection et de prévention des incendies de forêt. L'évolution technologique des satellites d'observation de la Terre permet aux chercheurs et gestionnaires forestiers d'accéder à des données multi spectrales, thermiques et topographiques de haute résolution, couvrant de vastes étendues géographiques à une fréquence d'acquisition régulière. Cette capacité d'observation continue rend possible une surveillance en quasi temps réel des conditions environnementales et de l'évolution des zones à risque, renforçant ainsi l'efficacité des systèmes d'alerte et d'intervention.

Les capteurs embarqués sur les satellites fournissent des images exploitables pour extraire des informations clés sur :

- l'état de la végétation,
- l'humidité des sols,
- la température de surface (LST),
- les zones brûlées,
- les anomalies thermiques signalant des départs de feu.

Ces données sont utilisées dans les systèmes d'alerte précoce, la planification des interventions, et la modélisation de la propagation des feux [9].

Sentinel-2 : Surveillance de la végétation et vulnérabilité

Le programme européen Copernicus, via les satellites Sentinel-2A et 2B, fournit des images multispectrales à une résolution spatiale de 10 à 60 mètres et avec une répétitivité de 5 jours, ce qui en fait un outil idéal pour la cartographie de la couverture terrestre et l'analyse de la végétation.

Les bandes spectrales dans le visible, le proche infrarouge (NIR) et l'infrarouge à ondes courtes (SWIR) sont particulièrement utiles pour calculer des indices de végétation.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Parmi les plus utilisés :

- NDVI (Normalized Difference Vegetation Index) : indicateur de la densité et de la santé de la végétation.
- NBR (Normalized Burn Ratio) : permet de détecter les zones brûlées et d'évaluer la sévérité des feux.
- SAVI (Soil Adjusted Vegetation Index) : corrige l'effet du sol nu dans les zones arides.

Ces indices permettent de suivre l'évolution de la sécheresse, d'identifier les zones de stress hydrique, et d'évaluer la résilience écologique post-incendie [9]. Les anomalies détectées dans ces indices sur plusieurs dates consécutives peuvent signaler des zones à risque élevé, notamment lorsqu'une baisse du NDVI précède des conditions météorologiques extrêmes.

❖ **MODIS : Détection rapide des anomalies thermiques**

Le capteur MODIS (Moderate Resolution Imaging Spectroradiometer), embarqué sur les satellites Terra et Aqua de la NASA, offre une couverture globale quotidienne. Bien que sa résolution soit plus faible (250 m à 1 km), sa fréquence élevée d'acquisition (1 à 2 passages par jour) est un atout majeur pour détecter rapidement des anomalies thermiques.

❖ **MODIS permet notamment :**

La détection des foyers actifs grâce aux bandes thermiques sensibles aux radiations infrarouges émises par le feu.

La génération de produits comme MOD14A1 (Thermal Anomalies & Fire Daily Global).

La création de cartes quotidiennes d'anomalies thermiques, intégrées dans des plateformes opérationnelles comme Fire Information for Resource Management System (**FIRMS**).

Grâce à MODIS, il est possible de déclencher des alertes précoces aux autorités locales en cas d'apparition soudaine de points chauds, limitant ainsi la propagation des incendies [10].

❖ Landsat : Suivi temporel et analyse post-incendie

La mission Landsat, développée par la NASA et l'USGS, offre depuis les années 1970 une archive historique de données satellitaires avec une résolution spatiale de 30 m. Bien que son intervalle de revisite soit de 16 jours, sa profondeur temporelle est précieuse pour :

- L'étude des dynamiques de changement de couverture forestière.
- L'analyse des tendances climatiques (chaleur, aridité) sur plusieurs années.
- La détection des zones brûlées (Burned Area Mapping) et la mesure de la sévérité des incendies.

Des produits comme le Normalized Burn Ratio (NBR), appliqués sur des images Landsat avant et après un incendie, permettent de calculer le dNBR (Delta NBR), utilisé dans la cartographie de la sévérité des incendies (faible, modérée, sévère). Cette approche est standardisée et utilisée par les agences comme USGS, FAO et Copernicus [10].

En somme, la télédétection permet une analyse globale et évolutive des risques d'incendie en combinant des données végétales, climatiques et thermiques sur différentes périodes. Grâce à cette capacité de surveillance étendue et continue, elle s'impose comme un outil essentiel dans les dispositifs actuels de prévention et de gestion des incendies de forêt.

II.3.2 Algorithmes de Machine Learning appliqués à la prédiction des incendies

Face aux limites des méthodes classiques de détection basées sur des seuils empiriques ou des modèles statistiques linéaires, les approches fondées sur le Machine Learning (**ML**) se sont imposées comme des solutions efficaces et flexibles. Leur capacité à apprendre des relations complexes entre plusieurs variables environnementales permet d'anticiper le comportement du feu à partir de données multi sources : images satellites, données météorologiques, topographiques, anthropiques, etc. [5].

Contrairement aux méthodes traditionnelles, les modèles ML peuvent être entraînés sur des données historiques, apprendre automatiquement les motifs de déclenchement d'incendies, et ensuite prédire la probabilité d'occurrence dans de nouvelles conditions environnementales [5], [10].

❖ Random Forest (RF)

Le Random Forest est l'un des algorithmes les plus populaires pour la classification des zones à risque d'incendie. Il repose sur une combinaison d'arbres de décision (ensemble learning) où chaque arbre est construit à partir d'un échantillon aléatoire de données.

Avantage :

- ✚ Très robuste aux données bruitées.
- ✚ Fonctionne bien sur des jeux de données de grande dimension.
- ✚ Moins sujet au surapprentissage que les arbres de décision classiques.
- ✚ Offre une mesure d'importance des variables, ce qui permet d'identifier les facteurs les plus influents (ex : température, humidité relative, NDVI, pente).

Résultats typiques :

Des études récentes, notamment celle de Rodrigues et al. [10], montrent que Random Forest peut atteindre une précision supérieure à 85% pour la prédiction de feux de forêt à partir de données Sentinel-2 et MODIS.

❖ Support Vector Machine (SVM)

Le SVM est un algorithme supervisé puissant, souvent utilisé lorsque les données sont non linéaires ou déséquilibrées — ce qui est courant dans les bases d'incendies (beaucoup plus de "non-feu" que de "feu").

Avantage :

- ✚ Capacité à gérer les jeux de données déséquilibrés, en trouvant la frontière optimale de séparation entre les classes.
- ✚ Très performant avec peu d'exemples d'incendies, lorsque la base est réduite.
- ✚ Permet l'utilisation de noyaux (kernels) pour modéliser des relations complexes.

Gradient Boosting & XGBoost

Les algorithmes de boosting, tels que Gradient Boosting Machine (**GBM**) et son implémentation optimisée XGBoost, sont aujourd'hui parmi les plus performants en prédiction de phénomènes complexes.

Avantage :

- ✚ Construisent des modèles séquentiels qui corrigent les erreurs précédentes.
- ✚ Offrent une très bonne précision même sur des données bruitées ou redondantes.
- ✚ XGBoost est reconnu pour sa vitesse d'entraînement, sa résistance au surapprentissage, et ses fonctionnalités avancées (early stopping, régularisation L1/L2).

Résultats typiques :

Dans les travaux de Rodrigues et al. [10], l'utilisation de XGBoost pour la prédiction de zones à haut risque a permis d'atteindre des scores F1 supérieurs à ceux de SVM et RF, notamment dans les zones avec fortes variations topographiques.

II.3.3 Travaux de recherche antérieurs sur la combinaison de ces technologies

Rodrigues et al. (2021) ont montré que l'intégration de données MODIS avec un modèle Random Forest permettait d'obtenir des précisions >85% dans la cartographie des zones à risque [10].

Au Maroc, Boulahfa et El Mourabit (2022) ont utilisé Sentinel-2 et Random Forest pour prédire les risques dans le Moyen Atlas, en intégrant aussi des données topographiques et climatiques [12].

Ces approches se sont révélées bien plus performantes que les modèles statistiques classiques, tant sur le plan de la précision que de la généralisation.

II.4 Cadre réglementaire et impact des incendies de forêt

II.4.1 Législation et politiques de prévention des incendies

Le Maroc a mis en place un arsenal juridique structuré pour faire face aux risques environnementaux, notamment les incendies de forêt. Parmi les textes fondamentaux figure la loi n°11-03 relative à la protection et à la mise en valeur de l'environnement, qui énonce les principes de gestion durable des ressources naturelles, la prévention des pollutions et des risques, ainsi que la responsabilité des acteurs publics et privés [13].

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Elle impose notamment la réalisation d'études d'impact environnemental pour les projets pouvant nuire aux écosystèmes sensibles, incluant les forêts.

Par ailleurs, le Code forestier marocain, bien qu'antérieur à la **loi 11-03**, reste un outil central dans la protection du domaine forestier. Il régle l'exploitation des ressources forestières, interdit le défrichement sans autorisation, sanctionne les atteintes aux forêts, et définit les responsabilités en cas d'incendie.

II.4.1.1 Rôle du HCEFLCD

Le Haut-Commissariat aux Eaux et Forêts et à la Lutte contre la Désertification (**HCEFLCD**) joue un rôle central dans la mise en œuvre des politiques de prévention des feux de forêt. Il coordonne les actions nationales à travers plusieurs dispositifs opérationnels [8] :

- Les plans de gestion forestière intégrant la cartographie des zones à risque ;
- L'aménagement de pare-feux pour limiter la propagation des flammes ;
- La surveillance préventive, assurée par des patrouilles terrestres et aériennes, particulièrement intensifiée durant la saison estivale ;
- Les campagnes de sensibilisation ciblant les populations rurales sur les comportements à risque (brûlis agricoles, dépôts de déchets, etc.) ;
- L'intégration de technologies modernes, telles que la télédétection, les stations météorologiques et les drones, pour améliorer la détection rapide des départs de feu.

Le HCEFLCD travaille en synergie avec la Protection Civile, les autorités territoriales, les Forces Armées Royales, ainsi que d'autres partenaires institutionnels, dans un cadre d'action concerté.

II.4.1.2 Coopération et initiatives internationales

Sur le plan international, le Maroc est engagé dans plusieurs programmes visant à renforcer ses capacités institutionnelles et techniques. Parmi eux figure le Plan Bleu pour la Méditerranée, émanant du Programme des Nations Unies pour l'Environnement (PNUÉ) dans le cadre du Plan d'Action pour la Méditerranée (PAM). Cette initiative vise à

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

promouvoir la coopération régionale, notamment en matière de prévention des incendies à travers l'échange d'expériences, d'outils de modélisation, et de systèmes de veille partagés [14].

Dans ce cadre, plusieurs projets ont permis au Maroc de bénéficier de systèmes d'alerte avancée et de cartes de risques dynamiques, intégrant des données climatiques et satellitaires pour anticiper les foyers potentiels. Par ailleurs, le Royaume a participé à des formations régionales et des exercices de simulation avec des pays du pourtour méditerranéen, en particulier l'Espagne, l'Italie et la France, avec qui il partage une coopération bilatérale renforcée.

Des dispositifs européens tels que l'Instrument de Préparation aux Catastrophes (**PREPARE**) ont également soutenu le développement de capacités locales, en apportant un appui logistique, matériel et en formant des équipes marocaines à l'utilisation d'outils SIG, de caméras thermiques ou de drones.

II.4.1.3 Limites actuelles et perspectives

Malgré ces avancées, plusieurs défis persistent. Les moyens humains et techniques restent parfois insuffisants face à l'augmentation de la fréquence et de l'intensité des feux, comme l'a montré l'incendie de Chefchaouen en 2022, qui a ravagé plus de 9 000 hectares de forêt [8]. Le manque de couverture continue dans certaines zones montagneuses, les retards de détection, ou encore la difficulté d'accès au terrain, limitent parfois l'efficacité des interventions.

Par ailleurs, la pression croissante exercée sur les écosystèmes forestiers par la croissance démographique, l'expansion des zones agricoles et l'urbanisation en périphérie des forêts contribue à accroître la vulnérabilité face aux incendies.

Dans ce contexte, il devient impératif de renforcer les dispositifs de prévention en adoptant des approches prédictives plus avancées, fondées sur l'intelligence artificielle, la télédétection multi-temporelle et la modélisation des risques en temps réel.

Une implication accrue des acteurs locaux et des communautés rurales dans ces stratégies est également essentielle pour assurer une gestion durable et efficace des risques d'incendie.

II.4.2 Impact environnemental des incendies

Les incendies de forêt ont des conséquences environnementales graves et durables, affectant plusieurs composantes des écosystèmes. Ces impacts ne se limitent pas uniquement à la destruction immédiate de la végétation, mais englobent également des effets indirects, persistants et parfois irréversibles, notamment dans les zones à forte sensibilité écologique comme le bassin méditerranéen.

II.4.2.1 Dégradation des sols

L'un des premiers effets visibles des incendies est la détérioration physique, chimique et biologique des sols. La chaleur intense détruit la matière organique présente en surface, réduisant la fertilité du sol et perturbant son équilibre hydrique. Le feu peut aussi provoquer la formation d'une couche hydrophobe, qui empêche l'infiltration de l'eau et favorise le ruissellement, entraînant une érosion accélérée.

Dans les zones de forte pente, comme celles de Chefchaouen, ce phénomène peut rapidement conduire à la déstructuration du sol, au lessivage des nutriments et à un appauvrissement généralisé du substrat, compromettant la régénération naturelle de la végétation.

II.4.2.2 Perte de biodiversité

Les forêts marocaines, notamment celles du nord du pays, abritent une faune et une flore riches et parfois endémiques, qui se retrouvent directement menacées par les feux. Les incendies provoquent la mort immédiate de nombreuses espèces animales, l'altération des habitats naturels et la disparition d'espèces végétales sensibles au stress thermique ou à la fragmentation de leur environnement [15].

Les espèces à faible mobilité, comme les reptiles, les rongeurs ou certaines plantes médicinales, sont les plus touchées. De plus, la disparition de la végétation de couverture peut rompre des chaînes trophiques entières, perturbant les équilibres écologiques pendant des années.

II.4.2.3 Accélération du changement climatique

Les feux de forêt libèrent dans l'atmosphère d'importantes quantités de dioxyde de carbone (CO₂), de méthane (CH₄) et d'autres gaz à effet de serre, contribuant ainsi directement au réchauffement climatique. Les forêts, en tant que puits de carbone, perdent leur capacité de stockage, aggravant l'effet cumulatif sur le climat.

Dans un contexte où les incendies deviennent plus fréquents et intenses, cette rétroaction positive amplifie les phénomènes climatiques extrêmes (sécheresse, canicules), créant un cercle vicieux difficile à rompre [15].

II.4.2.4 Ralentissement des processus de régénération

Dans les écosystèmes méditerranéens, où le climat est déjà marqué par des conditions extrêmes (chaleurs intenses, précipitations irrégulières), les processus de régénération post-incendie sont particulièrement lents. Il peut falloir plusieurs décennies pour que la couverture végétale se rétablisse, surtout en l'absence d'interventions humaines comme le reboisement ou la gestion écologique des zones sinistrées.

Pendant cette période, les écosystèmes restent vulnérables à de nouvelles perturbations, notamment à l'érosion, à l'invasion d'espèces exotiques, ou à des incendies successifs qui peuvent empêcher toute récupération naturelle.

II.4.3 Effets socio-économiques

Au-delà de leur impact écologique, les incendies de forêt ont des répercussions socio-économiques profondes, particulièrement marquées dans les régions rurales et montagneuses. Ces effets se manifestent à court, moyen et long terme, touchant à la fois les infrastructures, les activités économiques, les finances publiques et les conditions de vie des populations locales.

❖ Pertes matérielles et infrastructurelles

L'un des effets immédiats des incendies est la destruction d'habitations, de bâtiments agricoles, de routes forestières et d'équipements publics. Dans certaines zones, les feux atteignent des villages entiers, provoquant des déplacements temporaires ou définitifs des populations, surtout lorsque les habitations se trouvent en bordure de forêts ou en zones montagneuses [6].

Les pertes matérielles sont souvent difficilement compensables, notamment pour les familles à faibles revenus ne disposant pas d'assurance ou d'un soutien suffisant de la part de l'État ou des collectivités locales.

❖ Perturbation des activités agricoles et forestières

Dans les régions rurales, les incendies causent l'interruption brutale des activités agricoles, notamment la destruction des cultures, des oliveraies, des ruches et des équipements d'irrigation. Les pertes de cheptel sont également fréquentes, surtout lorsque les animaux pâturent à proximité des zones incendiées.

Pour les communautés montagnardes, très dépendantes des ressources naturelles, cela se traduit par une perte directe de revenus, qui peut entraîner à moyen terme l'abandon des terres agricoles, la migration vers les centres urbains et l'aggravation de la pauvreté locale [6].

En parallèle, les incendies affectent les ressources forestières exploitables, telles que le bois, les plantes médicinales, les champignons ou encore l'apiculture forestière. Leur disparition prive les habitants d'une source essentielle de subsistance.

❖ Effondrement du tourisme vert

Les incendies affectent également le secteur du tourisme rural et écologique, en pleine expansion dans des régions comme Chefchaouen, réputée pour ses paysages forestiers et ses sentiers de randonnée. La dégradation visuelle des paysages, la fermeture des sites naturels, et les restrictions d'accès imposées pour des raisons de sécurité provoquent une baisse de fréquentation touristique, souvent prolongée.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Cela impacte directement les activités de restauration, d'hébergement local, de guidage et d'artisanat, créant un effet boule de neige sur l'économie régionale.

❖ **Coût de la lutte contre les incendies**

La mobilisation des moyens de lutte (camions-citernes, hélicoptères, avions Canadair, effectifs humains, surveillance aérienne) engendre des coûts très élevés pour les pouvoirs publics. À cela s'ajoutent les frais post-incendie, liés au nettoyage des zones sinistrées, à la réhabilitation des infrastructures, à l'assistance aux sinistrés et aux programmes de reboisement [6].

Ces dépenses exceptionnelles pèsent lourdement sur les budgets régionaux et nationaux, détournant parfois des ressources initialement destinées à d'autres secteurs sociaux.

❖ **Vulnérabilité sociale accrue**

Enfin, les incendies exacerbent la vulnérabilité sociale des communautés rurales. Outre les pertes économiques, ces populations subissent un stress psychologique important, lié à la peur de revivre un incendie, à l'incertitude économique, ou encore à la dégradation de leur cadre de vie.

Dans certains cas, cela peut entraîner une rupture du lien homme-nature, une démobilisation communautaire ou un désengagement vis-à-vis des actions de prévention, rendant les zones sinistrées encore plus sensibles aux risques futurs.

CONCLUSION

Les incendies forestiers dégradent les sols et la biodiversité, comme à Chefchaouen en 2022.

Ils émettent de grandes quantités de CO₂ et CH₄, aggravant le changement climatique. Les populations rurales subissent pertes matérielles, interruption des activités et stress. Les coûts de lutte et de réhabilitation pèsent lourd sur les finances publiques. Il est indispensable de déployer des outils prédictifs basés sur l'IA et la télédétection, en impliquant les acteurs locaux.

III. PRESENTATION DE LA ZONE D'ETUDE

III.1 Présentation générale de la province de Chefchaouen

La province de Chefchaouen est située au nord du Maroc, dans la région Tanger-Tétouan-Al Hoceïma. Elle couvre une superficie d'environ 4 350 km² et se caractérise par une topographie montagneuse dominée par le massif du Rif, avec des altitudes dépassant parfois les 2 000 mètres. Cette configuration géographique confère à la région une richesse écologique remarquable mais également une vulnérabilité accrue aux aléas naturels, notamment les incendies de forêt.

Chefchaouen est majoritairement rurale : plus de 85 % de sa population vit dans des zones dépendantes de l'agriculture, du pâturage, de la cueillette, et de l'exploitation forestière à petite échelle. Cette cohabitation étroite entre l'homme et la forêt favorise l'émergence d'incendies, qu'ils soient accidentels ou liés à des pratiques agricoles traditionnelles [8], [16].

La province abrite également le Parc National de Talassemtane, une zone protégée qui englobe des forêts endémiques et des espèces rares. Toutefois, cette richesse écologique est menacée par une pression anthropique croissante et des risques naturels de plus en plus intenses [18].



Figure 10: Localisation de la province de Chefchaouen.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 11 : Localisation et caractéristiques géographiques de la province de Chefchaouen.




Figure 12 : Superficie forestière de la province de Chefchaouen par commune.

III.2 Caractéristiques climatiques et météorologiques

Chefchaouen bénéficie d'un climat méditerranéen à influence montagnarde, caractérisé par des étés secs et chauds et des hivers doux à froids. La pluviométrie annuelle est relativement élevée, oscillant entre 800 mm et 1 200 mm, mais elle est mal répartie dans le temps : la majeure partie des précipitations est concentrée entre novembre et mars [17].




Figure 13 : Diagramme ombrothermique Chefchaouen [19].

Le mois le plus sec est celui de Juillet avec seulement 3 mm. En moyenne, la plus grande quantité de précipitations se produit pendant Novembre avec une valeur moyenne de 117 mm [19].

Les températures estivales atteignent régulièrement 38 °C dans les vallées, tandis que l'humidité relative peut chuter sous 30 %, créant des conditions idéales pour l'ignition et la propagation rapide des feux. Le vent de type chergui, sec et chaud, souffle fréquemment sur les pentes exposées et accélère la combustion de la végétation sèche.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 14 : Courbe de température Chefchaouen [19].

Le mois le plus chaud de l'année est celui de Aout avec une température moyenne de 24.4 °C. En moyenne, le mois de Janvier est considéré comme la période la plus froide de l'année, avec des températures moyennes d'environ 8.2 °C [19].

Tableau 1 : Climat de Chefchaouen 1991-2021.

	Janvier	Février	Mars	Avril	Mai	Juin	Juillet	Août	Sep- tembre	Octobre	Novembre	Décembre
Température moyenne (°C)	8.2	8.6	10.8	12.7	16	20.5	24.1	24.4	20.4	16.0	11.6	8.3
Température minimale moyenne (°C)	4.8	4.8	6.8	8.2	11.1	14.9	18	18.8	16	13	8.3	6
Température maximale (°C)	12.6	13.3	15.8	17.8	21.2	26.5	30.5	30.8	25.9	21.8	15.8	12.8
Précipitations (mm)	84	92	105	67	68	17	3	10	46	110	117	117
Humidité(%)	82%	80%	70%	75%	70%	63%	55%	58%	63%	75%	70%	82%
Jours de pluie (jée)	7	7	7	8	7	2	1	1	5	7	7	7
Heures de soleil (h)	5.4	5.7	6.7	7.5	9.1	11.2	12.0	11.0	8.8	7.2	5.8	5.2

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Selon Ruffault et al. [2], l'augmentation des vagues de chaleur prolongées dans le bassin méditerranéen est l'un des principaux catalyseurs des feux extrêmes. Ce phénomène est observé dans les séries climatiques récentes de la province de Chefchaouen, où les étés deviennent plus longs et plus secs [1], [17].

III.3 Végétation et couverture forestière

La couverture végétale de la province est estimée à plus de 160 000 hectares, ce qui en fait l'une des régions les plus boisées du Maroc. On y retrouve plusieurs espèces forestières typiques des écosystèmes méditerranéens :

- Chênes-lièges (*Quercus suber*) et chênes verts (*Quercus ilex*) ;
- Pins d'Alep (*Pinus halepensis*) et pins maritimes (*Pinus pinaster*) ;
- Cèdres de l'Atlas (*Cedrus atlantica*) et sapins endémiques (*Abies marocana*) dans les zones d'altitude [8], [18].

Tableau 2 : Taux du couvert forestier dans la région de Chefchaouen.

Type de formations	Type d'essences	Superficie (ha)	Taux du couvert (%)
Résineuses naturelles	Cèdre	4 000	2
	Thuya	3 500	2
	Pins	10 000	4
	Sapin	3 000	1
Feuillues naturelles	Chêne vert	24 000	10
	Chêne liège	60 000	26
	Chêne zéen	3 000	1
Autres essences (+ reboisement)		31 500	14
Matorral		90 000	39
Total		229 000	100

Cette diversité biologique est un atout écologique mais également un facteur de risque. En effet, la structure dense et inflammable de ces forêts, notamment en saison sèche, favorise des départs de feu spontanés ou d'origine humaine.

L'indice de végétation NDVI mesuré à partir des données Sentinel-2 montre une chute significative de la densité chlorophyllienne entre juin et août, signe de stress hydrique intense [9], [12].

De plus, la surexploitation du bois, la pression pastorale, et l'extension des zones agricoles sur les forêts contribuent à la fragmentation écologique et à l'augmentation de la charge combustible, aggravant ainsi la vulnérabilité aux incendies [5].

III.4 Facteurs de risque spécifiques à la région

III.4.1 Topographie accidentée

Les pentes abruptes, les ravins étroits et l'enclavement de nombreux villages compliquent l'accès aux zones de feu. Cela ralentit considérablement les opérations de surveillance et d'intervention, augmentant la surface touchée par les flammes [10], [18].

III.4.2 Activités humaines à haut risque

Des pratiques agricoles non maîtrisées comme :

- le brûlage des chaumes.
- la fabrication artisanale de charbon de bois.
- les feux de camp illégaux sont responsables de plus de 40 % des départs de feu enregistrés selon les données du HCEFLCD [8]



Figure 15 : représente brûlage des chaumes.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection



Figure 16 : représente la fabrication artisanale de charbon de bois.



Figure 17 : Exemple de combustion illégale de déchets en milieu naturel.

III.4.3 Conditions climatiques extrêmes

La combinaison de fortes chaleurs, vents secs, sols arides et végétation inflammable est particulièrement présente dans les zones forestières entre 300 et 1 000 m d'altitude. Selon Pausas & Keeley [15], ces conditions sont typiques des "régimes de feu méditerranéens" qui génèrent des mégafeux rapides et destructeurs.

III.4.4 Faiblesse des dispositifs de surveillance

Malgré les efforts d'équipement, de nombreuses zones forestières restent hors de portée des patrouilles terrestres ou non couvertes par des capteurs thermiques. La mise en place de systèmes intelligents de détection par télédétection est donc une priorité stratégique [14].

IV. MATÉRIEL ET MÉTHODES

Ce chapitre présente en détail les données, outils et techniques mobilisés pour réaliser l'analyse et la prédiction des risques d'incendie de forêt dans la province de Chefchaouen, en s'appuyant sur des sources de données ouvertes, une chaîne de traitement dématérialisée, et des modèles de machine learning adaptés à la classification supervisée.

IV.1 Logiciel outils d'analyse

IV.1.1 Google Earth Engine (GEE)

Google Earth Engine (GEE) est une plateforme cloud développée par Google, conçue pour l'analyse et le traitement de données géospatiales à grande échelle. Elle permet d'accéder à une vaste collection d'images satellites et de données environnementales, tout en offrant des outils puissants pour le traitement, la visualisation et l'analyse à l'aide de scripts en JavaScript ou Python. GEE est largement utilisée dans les domaines de la télédétection, du suivi environnemental, de la gestion des ressources naturelles, et de la recherche scientifique, grâce à sa capacité à gérer efficacement de grands volumes de données spatiales.




Figure 18 : Interface de la plateforme Google Earth Engine utilisée pour l'extraction et le traitement des données géospatiales.

GEE a été utilisé pour l'extraction, le prétraitement et la fusion des différentes sources de données spatiales et temporelles. Ce puissant environnement cloud a permis de manipuler de grands volumes de données sans contraintes locales de stockage ou de puissance de calcul.

IV.1.2 Python et Jupyter Notebook

Python est un langage de programmation open source, simple, lisible et largement utilisé dans le domaine scientifique pour l'analyse de données, l'intelligence artificielle et le traitement des données géospatiales. Grâce à ses nombreuses bibliothèques (comme NumPy, Pandas, Scikit-learn, TensorFlow, etc.), il permet de manipuler efficacement des ensembles de données complexes et de mettre en œuvre des algorithmes avancés de machine learning.

Jupyter Notebook est un environnement interactif basé sur le web qui permet de combiner du code Python, du texte explicatif (en Markdown), des équations mathématiques (LaTeX) et des visualisations dans un seul document. Il est particulièrement adapté pour les travaux de recherche, l'analyse de données, la reproductibilité scientifique et le développement de prototypes de modèles.




Figure 19 : Interface de Google Colab utilisée pour l'analyse des données et l'entraînement des modèles de machine learning.

Les données exportées depuis GEE ont été analysées dans Jupyter Notebook à l'aide du langage Python, qui permet une programmation flexible et interactive. Les étapes de modélisation, d'entraînement des algorithmes et d'évaluation des performances ont été intégralement menées dans cet environnement.

IV.1.3 Bibliothèques utilisées

Scikit-learn est une bibliothèque open source en Python largement utilisée pour la mise en œuvre des algorithmes de machine learning supervisé et non supervisé. Elle fournit un ensemble cohérent d'outils simples, efficaces et bien documentés pour effectuer l'ensemble du processus d'apprentissage automatique, depuis la préparation des données jusqu'à l'évaluation des modèles.

Dans le cadre de ce projet, Scikit-learn a été employé pour réaliser les étapes classiques du machine learning, à savoir :

Séparation des données : à l'aide de la fonction `train_test_split`, le jeu de données est divisé en deux sous-ensembles : un ensemble d'entraînement (utilisé pour l'apprentissage du modèle) et un ensemble de test (utilisé pour évaluer ses performances sur des données jamais vues). Cette étape est cruciale pour éviter le surapprentissage (overfitting) et garantir la capacité de généralisation du modèle.

Entraînement des modèles : Scikit-learn offre une large gamme de modèles prédictifs, tels que les forêts aléatoires (Random Forest), le gradient boosting, le support vector machine (SVM), ou encore les k-plus proches voisins (KNN). Ces modèles sont entraînés en appelant la méthode `.fit()` sur les données d'entraînement, ce qui permet au modèle d'apprendre les relations entre les variables explicatives et la variable cible.

Évaluation des performances : pour juger de la qualité des prédictions, Scikit-learn propose plusieurs métriques d'évaluation adaptées au type de problème (classification ou régression). Dans le cas d'une classification, les indicateurs tels que la précision (accuracy), le rappel (recall), la F-mesure (F1-score) et la matrice de confusion ont été utilisés via les fonctions comme `classification_report`, `confusion_matrix`, et `f1_score`.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Grâce à sa simplicité d'utilisation, sa compatibilité avec d'autres bibliothèques comme NumPy et Pandas, et la richesse de ses fonctionnalités, Scikit-learn s'est imposée comme une solution robuste pour l'expérimentation et la mise en œuvre des modèles de machine learning dans ce projet.

XGBoost

XGBoost (Extreme Gradient Boosting) est une bibliothèque optimisée de machine learning basée sur l'algorithme de Gradient Boosting, conçue pour offrir des performances élevées, une grande efficacité et une grande flexibilité. Elle est particulièrement adaptée aux tâches de classification et de régression, et largement utilisée dans les compétitions de data science pour sa capacité à gérer des ensembles de données complexes et volumineux tout en maintenant une excellente précision.

Dans ce projet, XGBoost a été utilisé pour implémenter des modèles de boosting performants dans le but d'identifier les zones à risque d'incendie à partir de données multivariées issues de la télédétection et de variables environnementales. Les principales caractéristiques de son utilisation incluent :

Construction itérative de modèles : XGBoost suit le principe du boosting, où les arbres de décision sont construits de manière séquentielle, chaque nouvel arbre corrigeant les erreurs des arbres précédents. Cela permet d'améliorer progressivement les prédictions et de minimiser la fonction de perte.

Optimisation avancée : Contrairement aux implémentations classiques du gradient boosting, XGBoost intègre plusieurs techniques avancées, telles que la régularisation (L1 et L2), la gestion automatique des valeurs manquantes, le parallélisme au niveau des arbres, et la réduction de surapprentissage, ce qui le rend particulièrement adapté aux données bruitées ou déséquilibrées.

Hyperparamètres configurables : Le modèle XGBoost peut être finement contrôlé via des hyperparamètres tels que le taux d'apprentissage (`learning_rate`), la profondeur maximale des arbres (`max_depth`), le nombre d'estimateurs (`n_estimators`), et d'autres paramètres influençant directement la performance et la vitesse d'entraînement du modèle.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Évaluation des performances : Après l'entraînement via la méthode .fit(), les prédictions sont évaluées à l'aide des métriques classiques comme la précision, le rappel, la F1-score et l'AUC, permettant de comparer les performances avec d'autres algorithmes testés.

En résumé, XGBoost a été un choix stratégique dans ce projet pour bénéficier à la fois d'une robustesse prédictive élevée, d'une excellente gestion de la complexité des données et d'un entraînement efficace, assurant ainsi des résultats fiables pour la détection des zones vulnérables aux incendies de forêt.

Pandas, NumPy et Matplotlib

Dans le cadre de ce projet, les bibliothèques Pandas, NumPy et Matplotlib ont joué un rôle fondamental dans la gestion, l'analyse et la visualisation des données utilisées pour l'entraînement des modèles de machine learning.

Pandas :

Pandas est une bibliothèque puissante dédiée à la manipulation et à l'analyse de données sous forme de tableaux (DataFrames). Elle a été utilisée pour :

- Charger les données issues des fichiers CSV générés depuis Google Earth Engine.
- Nettoyer les données (suppression des valeurs manquantes, filtrage des doublons, renommage des colonnes).
- Réaliser des opérations statistiques de base (moyennes, écarts-types, distributions).
- Créer et manipuler facilement des ensembles d'entraînement et de test avant la modélisation.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

 NumPy :

NumPy est une bibliothèque fondamentale pour le calcul numérique avec Python, fournissant des structures de données efficaces comme les tableaux multidimensionnels (`numpy.array`) et des fonctions mathématiques rapides. Dans ce projet, elle a été utilisée pour :

- Réaliser des calculs mathématiques vectorisés (normalisation, standardisation des variables).
- Convertir les données entre différents formats (DataFrame vers tableau pour l'entraînement des modèles).
- Assurer une compatibilité optimale avec les bibliothèques de machine learning comme Scikit-learn ou XGBoost.

 Matplotlib :

Matplotlib est la bibliothèque de référence pour la visualisation statique des données. Elle a été mobilisée pour :

- Générer des graphiques d'exploration de données (histogrammes, courbes de densité, boxplots).
- Afficher les performances des modèles à l'aide de matrices de confusion, courbes ROC ou barres de comparaison des scores.
- Produire des illustrations claires et personnalisées intégrables dans le rapport scientifique.

L'association de ces trois bibliothèques constitue une boîte à outils complète et cohérente pour le traitement des données, permettant une préparation rigoureuse des variables et une compréhension approfondie des résultats à travers des visualisations efficaces.

IV.2 Méthodologie adoptée



Figure 20 : Schéma global du processus de prédiction des incendies de forêt.

IV.2.1 Prétraitement des données

Les données géospatiales extraites ont été nettoyées afin d'éliminer les valeurs manquantes ou aberrantes. Un processus de normalisation min-max a ensuite été appliqué à l'ensemble des variables continues pour les rendre compatibles avec les algorithmes de classification. Une sélection des variables a été réalisée en fonction de leur pertinence (corrélations avec l'occurrence d'incendies) afin d'éviter la redondance et réduire la complexité du modèle.

IV.3 Données utilisées

IV.3.1 Données satellitaires

Pour la détection et la prédiction des incendies de forêt, plusieurs sources de données satellitaires ont été mobilisées. Les images optiques à haute résolution de Sentinel-2 ont été utilisées pour extraire des indices de végétation tels que le NDVI, le NDMI et le NBR, permettant d'évaluer la santé de la végétation, le stress hydrique et les traces de brûlure.

Détection et prédiction des risques d'incendie forestier

dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Les données du capteur MODIS ont été exploitées pour compléter l'analyse temporelle grâce à leur haute fréquence de revisite, notamment pour les détections thermiques (produits de feu actifs). Enfin, Landsat-8 a permis d'intégrer des observations supplémentaires à moyenne résolution spatiale, renforçant la robustesse des variables extraites.

Tableau3: Description des données exploitées dans le projet.

Variable	Description	Source	Type
NDVI	Indice de végétation	Sentinel-2 (GEE)	Numérique
NDMI	Indice d'humidité de la végétation	Sentinel-2 (GEE)	Numérique
NBR	Indice des zones brûlées	Sentinel-2 (GEE)	Numérique
TEMP_norm	Température moyenne normalisée	ERA5-Land (GEE)	Numérique
HUM_norm	Humidité normalisée (point de rosée)	ERA5-Land (GEE)	Numérique
PRECIP_norm	Précipitations cumulées normalisées	ERA5-Land (GEE)	Numérique
Altitude & pente	Dérivées du Modèle Numérique de Terrain (SRTM)	SRTM (GEE)	Numérique
label_incendie	1 = zone brûlée, 0 = zone non brûlée (2015–2023)	Burned Area / FIRMS (GEE)	Binaire
latitude	Coordonnée géographique (latitude du pixel)	Automatique (GEE)	Numérique
longitude	Coordonnée géographique (longitude du pixel)	Automatique (GEE)	Numérique




Figure 21 : Délimitation de la zone d'étude : province de Chefchaouen dans Google Earth Engine.

Détection et prédiction des risques d'incendie forestier

dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Cette figure montre la zone géographique sélectionnée pour l'étude, correspondant aux limites administratives de la province de Chefchaouen. Cette zone est utilisée pour extraire, analyser et croiser les données géospatiales et environnementales dans le cadre de la prédiction des risques d'incendie de forêt.



Figure 22 : Visualisation et calcul des indices de végétation (NDVI, NDMI, NBR) dans la région de Chefchaouen via Google Earth Engine.




Figure 23 : Carte de l'indice de végétation NDVI pour la province de Chefchaouen à partir des images Sentinel-2 (année 2023).

Détection et prédiction des risques d'incendie forestier

dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Cette figure présente la distribution spatiale du NDVI dans la province de Chefchaouen, calculée à partir des bandes rouge (B4) et proche infrarouge (B8) des images Sentinel-2 acquises en 2023. L'indice NDVI permet d'évaluer la densité et la vigueur de la végétation.




Figure 24 : Carte de l'indice d'humidité NDMI pour la province de Chefchaouen à partir des images Sentinel-2 (année 2023).

Cette figure présente la distribution spatiale du NDMI dans la province de Chefchaouen, calculée à partir des bandes proche infrarouge (B8) et infrarouge moyen (B11) des images Sentinel-2 acquises en 2023. L'indice NDMI permet d'estimer le contenu en humidité de la végétation, un paramètre important pour la surveillance du stress hydrique et des risques d'incendie.




Figure 25 : Carte de l'indice NBR pour la province de Chefchaouen à partir des images.

Cette figure illustre la répartition spatiale de l'indice NBR dans la province de Chefchaouen, calculé à partir des bandes proche infrarouge (B8) et infrarouge moyen (B12) des images Sentinel-2 acquises en 2023. L'indice NBR est couramment utilisé pour détecter les zones brûlées et surveiller les changements liés aux incendies de végétation.

IV.3.2 Données météorologiques

Bien que les données météorologiques aient été collectées (température, humidité relative, précipitations, vitesse du vent), leur contribution au modèle final a été écartée après une phase d'expérimentation. En effet, ces variables, issues de la plateforme ERA5-Land, n'ont pas significativement amélioré la performance des modèles prédictifs dans notre cas d'étude.

Cette figure illustre la température moyenne annuelle de la province de Chefchaouen en 2023, calculée à partir du produit MODIS LST (Land Surface Temperature). Les valeurs sont exprimées en degrés Celsius et permettent d'identifier les zones plus chaudes ou plus fraîches, information utile pour l'analyse des conditions de vulnérabilité aux incendies.




Figure 26 : Carte de la température moyenne annuelle en 2023 dans la province de Chefchaouen, issue des données MODIS.

Détection et prédiction des risques d'incendie forestier dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 27 : Interface de traitement et de visualisation dans Google Earth Engine (GEE) montrant le script d'analyse des précipitations mensuelles à Chefchaouen entre 2018 et 2023.




Figure 28 : Variation mensuelle des précipitations moyennes (en mm) dans la province de Chefchaouen de 2018 à 2023, obtenue à partir des données ERA5-Land agrégées via GEE.

Cette figure représente l'évolution mensuelle des précipitations totales moyennes (en millimètres) enregistrées entre 2018 et 2023 dans la province de Chefchaouen.

Les données sont issues du jeu de données ERA5-Land du service Copernicus, traité via Google Earth Engine. Chaque barre du graphique correspond à la somme des précipitations d'un mois donné, permettant de visualiser les variations saisonnières sur plusieurs années.

Détection et prédiction des risques d'incendie forestier

dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

L'analyse de cette variable est essentielle pour évaluer la disponibilité en eau et le stress hydrique, deux facteurs clés influençant la vulnérabilité des écosystèmes face aux incendies de forêt.

Les données historiques :

Les données historiques des feux de forêt ont été obtenues à partir de sources géospatiales disponibles sur Google Earth Engine. Elles contiennent des informations sur les zones brûlées identifiées par détection satellitaire (produits Burned Area), permettant d'attribuer un label binaire (0/1) à chaque pixel du dataset : 1 pour une zone ayant subi un incendie durant la période d'étude (2015–2023), et 0 sinon.




Figure 29 : Carte binaire des zones brûlées dans la province de Chefchaouen entre 2010 et 2023 à partir des données MODIS MCD64A1.

Cette carte met en évidence les zones ayant été affectées par au moins un incendie de forêt au cours de la période 2015–2023, selon le produit MODIS Burned Area (MCD64A1). Les pixels en rouge indiquent les zones brûlées (label_incendie = 1), utilisées comme données d'entraînement supervisé pour les modèles de prédiction.

IV.3.3 Données topographiques et anthropiques

Des variables physiques comme l'altitude, la pente et occupation du sol ont été extraites du Modèle Numérique d'Élévation (SRTM). Ces facteurs influencent directement le comportement des incendies. De plus, la proximité aux routes et la densité de population ont été ajoutées en tant que variables anthropiques, car les zones proches des infrastructures humaines présentent souvent un risque accru d'incendies.




Figure 30 : Carte de l'altitude dans la province de Chefchaouen à partir du Modèle Numérique de Terrain(MNT SRTM, 30 m).

Cette figure présente la variation de l'altitude dans la province de Chefchaouen, dérivée du Modèle Numérique de Terrain (SRTM) avec une résolution de 30 mètres. Les valeurs sont exprimées en mètres et reflètent le relief de la région, un facteur important dans la propagation des incendies de forêt.

Détection et prédiction des risques d'incendie forestier

dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 31 : Carte de la pente en degrés dans la province de Chefchaouen à partir du Modèle Numérique de Terrain (MNT SRTM, 30 m).

Cette figure illustre la pente du terrain dans la province de Chefchaouen, calculée à partir du Modèle Numérique de Terrain (SRTM). Les valeurs sont exprimées en degrés et permettent d'identifier les zones escarpées ou plates. La pente est un facteur important dans la propagation des incendies, notamment en facilitant la montée rapide du feu sur les versants inclinés.




Figure 32 : Carte d'occupation du sol dans la province de Chefchaouen selon les données (ESA WorldCover 2021)

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Cette figure représente les différentes classes d'occupation du sol dans la province de Chefchaouen, issues du produit ESA WorldCover 2023 à 10 mètres de résolution. Chaque couleur correspond à une catégorie (forêts, terres agricoles, zones bâties, etc.), permettant d'analyser l'impact de l'usage du sol sur le risque d'incendie et la distribution des combustibles.

IV.3.4 Implémentation des modèles de machine learning

Dans cette étude, nous évaluons l'efficacité de plusieurs modèles de machine learning pour la prédiction des zones à risque d'incendie de forêt. Le jeu de données utilisé est constitué de 1656 points géolocalisés, chacun enrichi de 10 variables environnementales pertinentes, telles que les indices de végétation (NDVI, NDMI, NBR), les données topographiques (altitude, pente), les conditions météorologiques (température, humidité, précipitations) et Label incendie.

Chaque point est annoté à l'aide d'une variable cible label_incendie, où la valeur 1 indique une zone ayant subi un incendie entre 2015 et 2023, tandis que la valeur 0 désigne une zone non affectée. Cette annotation a été obtenue à partir de l'intersection entre les données de zones brûlées (produit MODIS MCD64A1) et les couches spatiales extraites via Google Earth Engine.

Cette approche permet de tirer parti de l'analyse géospatiale et des algorithmes d'apprentissage automatique pour identifier les zones les plus vulnérables aux incendies, dans le but de renforcer les efforts de prévention, de surveillance et de gestion des risques dans la province de Chefchaouen.

La figure ci-dessous représente un fichier Excel qui contient la dataset qu'on a rempli.

Dataset Complet Avec Statistiques

id	longitude	latitude	NDVI	NDBI	label_incendie	TEMP_scm	WV_scm	PRECIP_scm
1	12.1778	30.0755	0.24951718136122	-0.06499192080	0	0.78023854223183	0.6128745763481	0.02171812221419
2	12.1781	30.0811	0.1814084750476	0.132274547490	1	0.7502547670346	0.3402330955334	0.03443331437156
3	12.1582	30.0957	0.27217711138473	-0.0717886132767	0	0.78023854223183	0.6128745763481	0.02171812221419
4	12.1627	30.1126	0.0404902191328	0.1719808782190	1	0.24951718136122	0.24951718136122	0.0000249994001
5	12.1621	30.1130	0.2315057438846	0.1707638365538	1	0.24951718136122	0.24951718136122	0.0000249994001
6	12.1661	30.1160	0.2315057438846	0.1707638365538	1	0.24951718136122	0.24951718136122	0.0000249994001
7	12.1738	30.0811	0.24951718136122	-0.06499192080	0	0.78023854223183	0.6128745763481	0.02171812221419
8	12.1778	30.0755	0.24951718136122	-0.06499192080	0	0.78023854223183	0.6128745763481	0.02171812221419
9	12.1661	30.0957	0.27217711138473	-0.0717886132767	0	0.78023854223183	0.6128745763481	0.02171812221419
10	12.1627	30.1126	0.0404902191328	0.1719808782190	1	0.24951718136122	0.24951718136122	0.0000249994001
11	12.1621	30.1130	0.2315057438846	0.1707638365538	1	0.24951718136122	0.24951718136122	0.0000249994001
12	12.1661	30.1160	0.2315057438846	0.1707638365538	1	0.24951718136122	0.24951718136122	0.0000249994001
13	12.1738	30.0811	0.24951718136122	-0.06499192080	0	0.78023854223183	0.6128745763481	0.02171812221419
14	12.1778	30.0755	0.24951718136122	-0.06499192080	0	0.78023854223183	0.6128745763481	0.02171812221419
15	12.1661	30.0957	0.27217711138473	-0.0717886132767	0	0.78023854223183	0.6128745763481	0.02171812221419
16	12.1627	30.1126	0.0404902191328	0.1719808782190	1	0.24951718136122	0.24951718136122	0.0000249994001
17	12.1621	30.1130	0.2315057438846	0.1707638365538	1	0.24951718136122	0.24951718136122	0.0000249994001
18	12.1661	30.1160	0.2315057438846	0.1707638365538	1	0.24951718136122	0.24951718136122	0.0000249994001
19	12.1738	30.0811	0.24951718136122	-0.06499192080	0	0.78023854223183	0.6128745763481	0.02171812221419
20	12.1778	30.0755	0.24951718136122	-0.06499192080	0	0.78023854223183	0.6128745763481	0.02171812221419

Figure 33 : La dataset utilisé pour trainer les modèle ML

IV.3.4.1 Random Forest

Le random forest est un algorithme d'apprentissage supervisé utilisé en machine learning pour la classification et la régression. Il fonctionne en construisant plusieurs arbres de décision lors de l'entraînement, chaque arbre votant pour la classe la plus populaire ou la valeur moyenne des sorties pour les régressions. L'ensemble des prédictions des arbres constitue la prédiction finale du modèle. Dans le contexte de la prédiction des incendies, le random forest est souvent utilisé pour analyser des variables telles que les conditions météorologiques, l'utilisation des terres et d'autres facteurs environnementaux afin de prédire la probabilité et l'étendue des incendies.

Ci-dessous le code utilisé pour faire l'entraînement du modèle (RF), et pour obtenir les performances de ce modèle.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 34 : Entraînement du modèle Random Forest pour la prédiction des incendies de forêt à partir de données géospatiales et environnementales.

Cette figure montre le code Python utilisé pour entraîner un modèle Random Forest sur un jeu de données de 1656 points géolocalisés dans la province de Chefchaouen. Le modèle utilise 10 variables explicatives pour prédire la variable cible `label_incendie`, indiquant la présence ou non d'un incendie.

Les hyperparamètres dans le contexte des random forests sont des réglages préalables essentiels qui déterminent comment le modèle est construit lors de l'entraînement. Chacun de ces paramètres, comme le nombre d'arbres (`n_estimators`), la profondeur maximale des arbres (`max_depth`), ou encore le critère de sélection des caractéristiques à chaque division de nœud (`max_features`), influence directement la performance et la capacité du modèle à généraliser sur de nouvelles données. Par exemple, dans notre meilleur ensemble d'hyperparamètres pour un modèle random forest, nous avons spécifié des options telles que 153 arbres à construire (`n_estimators`), une profondeur maximale de 38 pour chaque arbre (`max_depth`), et l'utilisation de 'log2' comme critère pour déterminer les meilleures caractéristiques à chaque division (`max_features`). Ces choix sont cruciaux car ils affectent la complexité du modèle et sa capacité à s'adapter aux données tout en évitant le surapprentissage.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

La source de données provient d'un fichier Excel contenant notre dataset, comprenant 480 points avec 9 caractéristiques et une variable cible indiquant la présence (1) ou l'absence (0) d'incendies. Le dataset est divisé en un ensemble d'entraînement (70%) et un ensemble de test (30%) pour évaluer la performance du modèle.

Le modèle est formé sur l'ensemble d'entraînement (X_{train} , y_{train}) à l'aide de la méthode `fit()`. Ensuite, il est utilisé pour prédire la variable cible sur l'ensemble de test (X_{test}), et les prédictions sont comparées aux valeurs réelles. Les performances du modèle sont évaluées à l'aide de diverses métriques telles que la matrice de confusion, la précision, la sensibilité, la spécificité, la valeur prédictive positive (PPV), la valeur prédictive négative (NPV) et l'Aire Sous la Courbe (AUC). Cette démarche permet une évaluation détaillée de la capacité du modèle à discriminer entre les points avec et sans incendies. Les métriques fournissent des insights sur la précision, la sensibilité, la spécificité et d'autres aspects de la performance du modèle, permettant ainsi une compréhension approfondie de son efficacité dans la prédiction des zones vulnérables aux incendies de forêt.

IV.3.4.2 Gradient Boosting

Le Gradient Boosting est une méthode d'apprentissage supervisé qui construit un modèle prédictif en séquence, chaque nouvel arbre cherchant à corriger les erreurs résiduelles des prédictions précédentes. Dans le contexte de la prédiction des incendies de forêt, le Gradient Boosting utilise cette approche itérative pour combiner efficacement des variables telles que les conditions météorologiques, la topographie et l'usage des terres. Cela permet de capturer les relations complexes entre ces facteurs et les incendies, améliorant ainsi la précision des prévisions par rapport aux méthodes traditionnelles.

Ci-dessous le code utilisé pour faire le training du modèle Gradient Boosting et pour obtenir les performances de ce modèle.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 35 : Entraînement du modèle Gradient Boosting pour la prédiction des incendies de forêt à partir de données géospatiales et environnementales.

Ce script utilise la bibliothèque Scikit-learn pour mettre en œuvre un modèle de Gradient Boosting Classifier afin de prédire les zones vulnérables aux incendies de forêt. Le modèle est configuré avec des hyperparamètres spécifiques tels que le taux d'apprentissage, le nombre d'estimateurs, la profondeur maximale de l'arbre, et d'autres paramètres pertinents pour améliorer les performances du modèle.

Les hyperparamètres dans le contexte du modèle Gradient Boosting sont des réglages préalables essentiels qui influencent directement la construction et la performance du modèle lors de l'entraînement. Parmi ces paramètres, le taux d'apprentissage (`learning_rate`), le nombre d'estimateurs (`n_estimators`), la profondeur maximale des arbres (`max_depth`), le sous-échantillonnage (`subsample`), et le critère de sélection des caractéristiques (`max_features`) jouent un rôle crucial. Par exemple, dans notre meilleur ensemble d'hyperparamètres pour le modèle Gradient Boosting, nous avons spécifié un taux d'apprentissage de 0.2, utilisé 177 arbres à construire (`n_estimators`), fixé une profondeur maximale de 7 pour chaque arbre (`max_depth`), choisi un sous échantillonnage de 70% (`subsample`), et utilisé 'sqrt' comme critère pour déterminer les meilleures caractéristiques à chaque division de nœud (`max_features`). Ces choix sont fondamentaux car ils impactent la complexité du modèle, sa capacité à généraliser sur de nouvelles données, et sa résistance au surapprentissage.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Les données proviennent d'un fichier Excel contenant un ensemble de 1656 points, chacun caractérisé par 9 features. Les variables telles que la latitude et la longitude sont prétraitées et des colonnes inutiles sont supprimées avant de diviser les données en ensembles d'entraînement (70%) et de test (30%).

Le modèle de Gradient Boosting est ensuite entraîné sur l'ensemble d'entraînement (X_train, y_train) à l'aide de la méthode fit(). Une fois entraîné, le modèle est utilisé pour prédire la variable cible sur l'ensemble de test (X_test), et ses performances sont évaluées à l'aide de plusieurs métriques telles que la matrice de confusion, la précision, la sensibilité, la spécificité, la valeur prédictive positive (PPV), la valeur prédictive négative (NPV) et l'Aire Sous la Courbe ROC (AUC).

Les résultats finaux offrent une évaluation détaillée de la capacité du modèle de Gradient Boosting à prédire les incendies de forêt, démontrant ainsi son efficacité dans l'identification des zones à risque.

IV.3.4.3 XGBoost

XGBoost (Extreme Gradient Boosting) est une méthode d'apprentissage supervisé basée sur le principe du boosting, qui améliore les performances en combinant plusieurs arbres de décision faibles de manière séquentielle. Chaque nouvel arbre est entraîné pour corriger les erreurs résiduelles commises par les arbres précédents, avec une régularisation intégrée pour éviter le surapprentissage.

Dans le contexte de la prédiction des incendies de forêt, XGBoost exploite efficacement des données hétérogènes telles que les conditions météorologiques, les variables topographiques, et l'occupation du sol, afin de modéliser les interactions complexes entre ces facteurs. Grâce à son efficacité computationnelle et sa capacité à gérer des jeux de données déséquilibrés, XGBoost permet d'atteindre une précision supérieure aux méthodes classiques, renforçant ainsi la détection préventive des zones à risque.

Ci- dessous le code utilisé pour faire le trainement du modèle XGBoost et pour obtenir les performances de ce modèle.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 36 : Entraînement du modèle XGBoost pour la prédiction des incendies de forêt à partir de données géospatiales et environnementales.

Ce script utilise la bibliothèque XGBoost (Extreme Gradient Boosting) pour mettre en œuvre un modèle de classification supervisée visant à prédire les zones vulnérables aux incendies de forêt. XGBoost est réputé pour sa robustesse, sa vitesse d'exécution et sa capacité à gérer les déséquilibres de classes, ce qui en fait un choix pertinent pour ce type d'analyse.

Dans ce modèle, plusieurs **hyperparamètres clés** ont été réglés afin d'optimiser les performances prédictives, notamment :

- le **taux d'apprentissage** (learning_rate),
- le **nombre d'estimateurs** (n_estimators),
- la **profondeur maximale** des arbres (max_depth),
- le **sous-échantillonnage** des données (subsample),
- la **proportion de colonnes utilisées par arbre** (colsample_bytree),
- et le paramètre **scale_pos_weight** qui permet de mieux gérer le déséquilibre entre classes (zones brûlées vs non brûlées).

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Par exemple, dans notre meilleure configuration, nous avons utilisé un taux d'apprentissage de **0.1**, un nombre total de **200 arbres** (`n_estimators`), une **profondeur maximale de 5**, un **sous-échantillonnage de 80%** (`subsample = 0.8`), une sélection de 80% des caractéristiques par arbre (`colsample_bytree = 0.8`), et un **poids ajusté automatiquement** pour compenser l'effet de la classe minoritaire (`scale_pos_weight ≈ 9.6`, correspondant au rapport entre classes 0 et 1 dans les données).

Les données utilisées proviennent d'un fichier CSV contenant **1656 points géolocalisés**, chacun décrit par **14 variables environnementales** pertinentes. Les colonnes inutiles (latitude, longitude) ont été supprimées, et les données ont été divisées en deux ensembles : **70 % pour l'entraînement** et **30 % pour le test**.

Le modèle XGBoost a été entraîné sur l'ensemble `X_train`, `y_train` à l'aide de la méthode `fit()`. Une fois l'apprentissage terminé, le modèle a été utilisé pour effectuer des prédictions sur l'ensemble de test (`X_test`). Ses performances ont été évaluées à l'aide de plusieurs métriques : la **matrice de confusion**, la **précision**, le **rappel (sensibilité)**, la **spécificité**, la **valeur prédictive positive (PPV)**, la **valeur prédictive négative (NPV)**, ainsi que **l'Aire Sous la Courbe ROC (AUC)**.

Les résultats finaux ont montré que le modèle XGBoost est particulièrement efficace pour détecter les zones à risque d'incendie, même dans un contexte de données déséquilibrées. Il s'est distingué par une **bonne capacité de généralisation**, une **détection précise des cas positifs**, et une **robustesse** face au bruit des données géospatiales. Cette approche démontre ainsi le potentiel de XGBoost comme outil fiable d'aide à la prévention et à la gestion des incendies de forêt.

IV.3.5 Évaluation des modèles

L'évaluation des performances des modèles de classification (Random Forest, Gradient Boosting, XGBoost) a été effectuée à l'aide d'indicateurs essentiels tels que la précision, la matrice de confusion et l'AUC (Area Under the Curve).

Ces métriques permettent de mesurer la capacité des modèles à distinguer efficacement les zones à risque d'incendie de celles qui ne le sont pas. La matrice de confusion fournit

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

une vision détaillée des prédictions correctes et erronées, tandis que l'AUC reflète la capacité globale du modèle à classer correctement les zones vulnérables.

L'intégration des données spatiales issues de Google Earth Engine avec les algorithmes de machine learning exécutés dans l'environnement Python (Google Colab) a permis de développer un système cohérent, capable de fournir des cartes de vulnérabilité précises. Cette approche combinée renforce les capacités d'anticipation et de planification, en facilitant la mise en place d'actions de prévention ciblées et fondées sur des analyses objectives.

V. RÉSULTATS ET DISCUSSION

V.1 Performance des modèles de prédiction

L'évaluation des performances des trois modèles optimisés s'est appuyée sur des métriques classiques de classification binaire : matrice de confusion, précision, rappel, F1-score et l'AUC (Area Under Curve).

- **Matrice de confusion :**

La matrice de confusion est un tableau à double entrée qui permet de visualiser les performances d'un modèle de classification en comparant les prédictions avec les valeurs réelles. Elle indique le nombre de vrais positifs (TP), vrais négatifs (TN), faux positifs (FP) et faux négatifs (FN), permettant ainsi d'évaluer finement les erreurs de classification.

- **Précision (Precision) :**

La précision mesure la proportion de prédictions positives correctes parmi l'ensemble des prédictions positives du modèle. Elle est définie par la formule :

$$\text{Précision} = \frac{TP}{TP + FP}$$

Elle indique la fiabilité du modèle lorsqu'il prédit une classe positive.

- **Rappel (Recall) :**

Le rappel évalue la capacité du modèle à détecter correctement toutes les occurrences positives dans les données. Il est donné par :

$$\text{Rappel} = \frac{TP}{TP + FN}$$

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Un rappel élevé signifie que le modèle identifie bien les cas positifs, même s'il produit quelques faux positifs.

- **F1-score :**

Le F1-score est la moyenne harmonique entre la précision et le rappel. Il fournit un équilibre entre ces deux métriques, notamment dans les cas de classes déséquilibrées :

$$\text{F1-score} = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

C'est une mesure globale de la performance d'un modèle de classification binaire.

- **AUC (Area Under Curve) :**

L'AUC correspond à la surface sous la courbe ROC (Receiver Operating Characteristic). Elle reflète la capacité du modèle à distinguer les classes positives des classes négatives. Une AUC proche de 1 indique une excellente capacité de discrimination, tandis qu'une AUC proche de 0.5 traduit une performance équivalente à un tirage aléatoire.

V.1.1 Random Forest

Le modèle Random Forest a affiché des résultats satisfaisants, avec une bonne capacité à distinguer les zones à risque.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 37 : Matrice de confusion du modèle Random Forest appliqué à la prédiction des risques d'incendie dans la province de Chefchaouen.

Cette matrice de confusion présente les performances du modèle Random Forest optimisé dans la classification des zones à risque d'incendie. Le modèle a correctement identifié 362 zones sans risque (classe 0) et 11 zones avec risque (classe 1). On observe 28 faux négatifs (zones à risque non détectées) et 5 faux positifs (zones incorrectement classées comme à risque). Ces résultats reflètent un bon équilibre entre sensibilité et spécificité, confirmant la capacité du modèle à discriminer efficacement les zones vulnérables.




Figure 38 : Courbe ROC du modèle Random Forest pour la prédiction des risques d'incendie dans la province de Chefchaouen.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Cela reflète un bon équilibre entre sensibilité et spécificité. Le **score AUC atteint 0.8734**, ce qui est légèrement supérieur aux deux autres modèles. Cela indique une meilleure capacité globale à discriminer entre les deux classes.

V.1.2 Gradient Boosting

Le modèle Gradient Boosting semble moins performant dans la détection des incendies Il présente :




Figure 39 : Matrice de confusion du modèle Gradient Boosting pour la prédiction des risques d'incendie dans la province de Chefchaouen.

Cette matrice de confusion montre les résultats du modèle Gradient Boosting. Le modèle a bien identifié 366 zones sans risque (classe 0) mais seulement 4 zones à risque (classe 1). Il a généré 35 faux négatifs, ce qui indique une difficulté à détecter les incendies réels, et seulement 1 faux positif. Ce comportement suggère une forte prudence du modèle, privilégiant la minimisation des fausses alertes au détriment du rappel.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 40 : Courbe ROC du modèle Gradient Boosting pour la prédiction des risques d'incendie dans la province de Chefchaouen.

La courbe ROC du modèle Gradient Boosting présente un AUC de 0.8579, ce qui indique une bonne capacité de discrimination entre les zones à risque et les zones sûres. Bien que légèrement inférieur à celui du modèle Random Forest, ce résultat reflète une performance globalement acceptable, mais avec une tendance à sous-estimer les cas positifs (incendies).

V.1.3 XGBoost

Le modèle XGBoost, bien qu'ayant de très faibles faux positifs (**2** seulement), détecte peu d'incendies :

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection




Figure 41 : Matrice de confusion du modèle XGBoost pour la prédiction des risques d'incendie dans la province de Chefchaouen.

Cette matrice de confusion montre les résultats du modèle XGBoost. Le modèle a correctement identifié 365 zones sans risque (classe 0) et seulement 3 zones à risque (classe 1). Il présente **36 faux négatifs** et 2 faux positifs, ce qui traduit une forte prudence dans la prédiction des incendies, au détriment du rappel. Bien que peu d'alertes soient générées à tort, plusieurs cas d'incendie réels ne sont pas détectés.




Figure 42 : Courbe ROC du modèle XGBoost pour la prédiction des risques d'incendie dans la province de Chefchaouen.


Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

La courbe ROC du modèle XGBoost montre une aire sous la courbe ($AUC = 0.8677$) indiquant une très bonne capacité de discrimination entre les zones à risque et celles sans risque. Bien que légèrement inférieur à Random Forest, ce modèle équilibre correctement le taux de vrais positifs et de faux positifs, tout en maintenant un faible taux de fausses alertes. Il se révèle donc robuste pour une utilisation en contexte de prévention.

V.2 Cartographie de la vulnérabilité

V.2.1 Modèle Random Forest

La carte de vulnérabilité générée par Random Forest (Figure 38) met en évidence une concentration significative de zones à risque extrême (en rouge) principalement dans le centre-sud et l'ouest de la province. Le modèle détecte aussi des foyers dispersés, ce qui indique une bonne sensibilité spatiale. Les zones à risque moyen (en jaune) sont plus étendues, entourant souvent les zones critiques.



Ces résultats confirment que le modèle Random Forest parvient à bien capturer la distribution géographique des zones vulnérables, notamment dans les régions où la végétation dense, la topographie accidentée et la proximité des zones habitées ou des infrastructures augmentent les risques d'incendie. La transition progressive entre les zones à risque extrême et moyen indique également que le modèle prend en compte la variabilité locale des facteurs de risque. Cette cartographie détaillée peut ainsi constituer un outil d'aide à la décision pour orienter les actions de prévention et les stratégies de surveillance dans les secteurs les plus exposés.

V.2.2 Modèle Gradient Boosting

En revanche, le Gradient Boosting (Figure 39) propose une cartographie plus conservatrice, avec très peu de zones classées en risque extrême, ce qui peut suggérer une sous-estimation des menaces. Les zones à risque élevé sont concentrées dans le centre et sud-est de la province. Cette représentation plus restrictive peut être utile pour éviter les fausses alertes, mais moins adaptée à des politiques de prévention agressives.




Figure 44: Carte de vulnérabilité aux incendies dans la province de Chefchaouen selon le modèle Gradient Boosting.

Cette carte met en évidence la tendance du modèle Gradient Boosting à limiter la détection des zones à haut risque, ce qui peut s'expliquer par sa forte précision sur la classe majoritaire (absence de feu), mais au détriment de la sensibilité sur la classe minoritaire (présence de feu). Ce comportement, bien que réducteur, peut être avantageux dans des contextes où les ressources pour la prévention sont limitées et où l'on souhaite éviter des interventions inutiles. Toutefois, une telle prudence peut entraîner la non-détection de certains foyers critiques, rendant ce modèle moins fiable dans les zones à forte pression environnementale.

V.2.3 Modèle XGBoost

La cartographie issue de XGBoost (Figure 40) montre des résultats plus similaires à ceux du Random Forest, avec une bonne couverture des zones à vulnérabilité extrême, en particulier dans les zones boisées et montagneuses. Cela souligne sa capacité à détecter les zones sensibles tout en conservant un faible taux de fausses alarmes.




Figure 45 : Carte de vulnérabilité aux incendies dans la province de Chefchaouen selon le modèle XGBoost.

La distribution des zones à risque identifiées par XGBoost témoigne d'un bon compromis entre sensibilité et précision. Le modèle réussit à couvrir une large étendue de zones potentiellement dangereuses, tout en limitant les fausses détections. Cette capacité à équilibrer les prédictions en fait un candidat pertinent pour des applications opérationnelles, notamment dans des contextes de surveillance continue. Néanmoins, malgré sa bonne performance globale, le modèle affiche encore quelques lacunes dans la détection complète des foyers d'incendie, comme le révèlent les résultats de la matrice de confusion. Une intégration avec d'autres sources d'information ou une hybridation avec des approches complémentaires pourrait améliorer encore ses performances.

V.3 Interprétation des résultats et complémentarité

L'analyse conjointe des résultats cartographiques et statistiques permet de tirer plusieurs constats :




Figure 46 : Courbe ROC comparative des modèles Random Forest, Gradient Boosting et XGBoost pour la prédiction des risques d'incendie dans la province de Chefchaouen.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Cette courbe ROC compare les performances des trois modèles optimisés. Le Random Forest affiche la meilleure performance globale avec un AUC de 0.8734, suivi par XGBoost (0.8677) et Gradient Boosting (0.8579). Plus la courbe se rapproche du coin supérieur gauche, plus le modèle est performant. Ces résultats confirment que les trois modèles sont efficaces, mais que Random Forest présente un léger avantage en matière de détection des zones à risque.

 Random Forest

Est le plus équilibré entre **détection** et **précision**, ce qui en fait un choix robuste pour la cartographie opérationnelle.

 Gradient Boosting

Bien que très précis pour les cas négatifs, manque de capacité à détecter les cas d'incendie.

 XGBoost

Offre un bon compromis, mais reste légèrement moins performant que le Random Forest selon l'AUC.

La représentation spatiale de la vulnérabilité issue des cartes interpolées confirme les observations précédentes : les modèles Random Forest et XGBoost affichent une répartition plus large et détaillée des zones à risque moyen à extrême, couvrant l'ensemble du territoire de manière cohérente avec les données d'entrée. En comparaison, le modèle Gradient Boosting produit une carte beaucoup plus restreinte, limitant fortement l'identification des zones à risque élevé, ce qui renforce l'idée de sous-estimation des menaces déjà constatée dans ses performances statistiques.

V.4 Limites des modèles

Bien que les modèles Random Forest, Gradient Boosting et XGBoost aient montré des performances globalement satisfaisantes dans la prédiction des risques d'incendie, plusieurs limites importantes doivent être soulignées, tant sur le plan des données que de l'approche algorithmique :

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

- **Déséquilibre des classes**

L'une des contraintes majeures dans ce projet est liée au déséquilibre important du jeu de données, avec un nombre très réduit de points réellement associés à des incendies (classe 1). Cette sous-représentation de la classe minoritaire limite considérablement la capacité des algorithmes à apprendre les caractéristiques discriminantes des zones à risque réel. En conséquence, plusieurs incendies ne sont pas détectés (faux négatifs), comme observé dans les matrices de confusion, notamment pour Gradient Boosting et XGBoost. Ce déséquilibre peut induire un biais vers la classe majoritaire (absence de feu), ce qui affecte la sensibilité des modèles.

- **Manque de certaines variables explicatives clés**

Le modèle s'appuie principalement sur des variables environnementales extraites de données satellitaires (indices de végétation, humidité, topographie, etc.). Toutefois, certaines variables cruciales pour la dynamique des incendies n'ont pas pu être intégrées, notamment :

- ❖ **Le vent** : facteur déterminant dans la propagation des feux, difficile à modéliser à l'échelle fine en raison de sa variabilité spatio-temporelle.
- ❖ **L'activité humaine ponctuelle** (ex. : agriculture, brûlage de déchets, présence de touristes, circulation sur les pistes forestières), souvent à l'origine de départs de feu, mais peu représentée dans les données géospatiales disponibles.
- ❖ **La densité de combustible** (matière sèche, types de végétation hautement inflammables), non disponible sous forme de données normalisées.

- **Limites des données satellitaires**

Certaines erreurs ou imprécisions inhérentes aux images satellites utilisées (résolution spatiale insuffisante, présence de nuages, erreurs de calibration) peuvent également impacter la qualité des variables extraites. Par ailleurs, les cartes de feu utilisées pour le label (par exemple à partir de FIRMS ou d'autres bases) peuvent ne pas détecter les petits feux ou les départs rapides, ce qui fausse l'étiquetage des données d'apprentissage.

- **Généralisation limitée**

Enfin, les modèles entraînés sur les données historiques d'une région spécifique (Chefchaouen) peuvent présenter une capacité de généralisation limitée si l'on souhaite les appliquer à d'autres territoires, en raison de différences climatiques, écologiques ou humaines. Cela implique qu'un ré-entraînement local serait nécessaire pour chaque nouvelle région étudiée.

VI. CONCLUSION ET PERSPECTIVES

VI.1 Synthèse des contributions du projet

Ce travail a permis de développer une approche méthodologique intégrée pour la détection et la prédiction des risques d'incendie de forêt dans la province de Chefchaouen, en combinant des données issues de la télédétection, des variables environnementales et des modèles de machine learning supervisés. Trois algorithmes ont été mis en œuvre : Random Forest, Gradient Boosting et XGBoost.

L'ensemble du processus, depuis la collecte des données satellitaires et topographiques, leur prétraitement dans Google Earth Engine, jusqu'à l'entraînement et l'évaluation des modèles dans Google Colab, a été réalisé de manière rigoureuse.

Les résultats montrent que :

- Le Random Forest est le modèle le plus équilibré, avec un AUC de 0.8734, une bonne capacité de détection et une cartographie cohérente des zones à risque.
- Le Gradient Boosting a présenté une forte prudence, avec très peu de fausses alertes, mais une faible capacité de détection des incendies réels.
- Le XGBoost a offert un bon compromis entre précision et rappel, avec une cartographie similaire à celle du Random Forest, mais une sensibilité légèrement inférieure.

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

Les cartes de vulnérabilité générées ont mis en évidence les zones critiques, notamment dans le centre, le sud et l'ouest de la province, apportant des informations précieuses pour les acteurs locaux en charge de la gestion des risques.

VI.2 Apport de la télédétection et du machine learning dans la prévention des incendies

L'utilisation combinée de la télédétection (indices NDVI, NDMI, NBR, données climatiques et topographiques) et du machine learning s'est révélée pertinente pour :

- Cartographier des zones de risque sur de grandes surfaces avec un coût réduit et une actualisation facile.
- Prédire les risques futurs à partir de l'historique des incendies et de variables explicatives pertinentes.
- Appuyer les décisions stratégiques en matière de surveillance et de déploiement de moyens de prévention.

Cette approche représente une alternative efficace aux méthodes traditionnelles, souvent limitées à des relevés de terrain coûteux et ponctuels.

VI.3 Limites et recommandations pour les travaux futurs

Certaines limites ont été identifiées au cours du projet :

- Le déséquilibre des classes a fortement influencé la capacité des modèles à détecter les feux réels.
- L'absence de variables clés comme le vent ou l'activité humaine en temps réel a limité la précision globale.
- Les modèles restent sensibles à la qualité des données satellites, et leur transférabilité géographique reste à tester.

Pour améliorer ces résultats, il est recommandé de :

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

- Renforcer l'équilibrage des classes à l'aide de méthodes avancées (SMOTE, ADASYN).
- Intégrer des données issues de capteurs météorologiques en temps réel.
- Évaluer les performances sur d'autres provinces pour valider la robustesse du modèle à grande échelle.

VI.4 Perspectives d'amélioration et d'intégration en temps réel

Les perspectives les plus prometteuses à court et moyen terme incluent :

- Le développement d'une plateforme automatisée (type dashboard) intégrant GEE et les modèles ML pour produire des cartes de risque en quasi temps réel.
- L'intégration de capteurs IoT, de drones et de réseaux de stations météo locales pour enrichir les données.
- La mise en œuvre d'un système d'alerte précoce ciblant les zones à forte vulnérabilité, pour permettre une intervention rapide.

Enfin, une collaboration étroite avec les acteurs institutionnels locaux (HCEFLCD, communes forestières, protection civile) serait nécessaire pour valoriser ce travail dans une optique opérationnelle.

Références

- [1] Bowman, D. M. J. S., Williamson, G. J., Abatzoglou, J. T., Kolden, C. A., Cochrane, M. A., & Smith, A. M. S. (2020). Human exposure and sensitivity to globally extreme wildfire events. *Nature Ecology & Evolution*, 4(1), 111–117. <https://doi.org/10.1038/s41559-019-1064-6>
- [2] Ruffault, J., Curt, T., Moron, V., Trigo, R. M., Mouillot, F., Koutsias, N., & Pimont, F. (2020). Increased likelihood of heat-induced large wildfires in the Mediterranean Basin. *Nature Communications*, 11(1), 1–10. <https://doi.org/10.1038/s41467-020-16962-3>
- [3] Haut-Commissariat aux Eaux et Forêts et à la Lutte Contre la Désertification (HCEFLCD). (2022). *Bilan des incendies de forêt au Maroc – Campagne 2022*. Rabat, Maroc. <https://www.eauxetforets.gov.ma/>
- [4] FAO. (2021). *Global Forest Resources Assessment 2020 – Morocco Country Report*. Food and Agriculture Organization of the United Nations. <https://www.fao.org/forest-resources-assessment/>
- [5] Jain, P., Coogan, S. C. P., Subramanian, S. G., Crowley, M., Taylor, S., & Flannigan, M. D. (2020). A review of machine learning applications in wildfire science and management. *Environmental Reviews*, 28(4), 478–505. <https://doi.org/10.1139/er-2020-0019>
- [6] Xu, R., Yu, P., Abramson, M. J., Johnston, F. H., Samet, J. M., Bell, M. L., & Guo, Y. (2020). Wildfires, global climate change, and human health. *New England Journal of Medicine*, 383(22), 2173–2181. <https://doi.org/10.1056/NEJMSr2028985>
- [7] Thomas, D. S. G., & Goudie, A. (2019). The Economics of Wildfire: Understanding economic losses and insurance implications. In *The Changing Climate and the Global Economy*. Oxford University Press.
- [8] Haut-Commissariat aux Eaux et Forêts et à la Lutte Contre la Désertification (HCEFLCD). (2023). *Rapport annuel sur les incendies de forêt – Campagne 2022*. Rabat, Maroc. <https://www.eauxetforets.gov.ma/>
- [9] Roy, D. P., Wulder, M. A., Loveland, T. R., Woodcock, C. E., Allen, R. G., Anderson, M. C., ... & Scambos, T. A. (2014). Landsat-8: Science and product vision for terrestrial global change research. *Remote Sensing of Environment*, 145, 154–172.
<https://doi.org/10.1016/j.rse.2014.02.001>

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection

[10] Rodrigues, M., de la Riva, J., & Fotheringham, A. S. (2021). Modeling the spatial pattern of wildfires in Europe using remote sensing and machine learning. *Environmental Modelling & Software*, 139, 105044.

<https://doi.org/10.1016/j.envsoft.2021.105044>

[11] FAO. (2020). *Terminology and Definitions for Forest Fire Management*. Food and Agriculture Organization of the United Nations.

<https://www.fao.org/3/i0826f/i0826f00.pdf>

[12] Boulahfa, I., & El Mourabit, I. (2022). Application of Remote Sensing and Random Forest Algorithm to Predict Forest Fire Risk in the Middle Atlas Region (Morocco). *Journal of Geographic Information System*, 14(6), 625–641.

<https://doi.org/10.4236/jgis.2022.146032>

[13] Royaume du Maroc. (2003). *Loi n° 11-03 relative à la protection et à la mise en valeur de l'environnement*. Bulletin Officiel n°5118.

[14] Plan Bleu. (2022). *Prévenir les incendies de forêt dans le bassin méditerranéen : stratégies, innovations et coopération régionale*. Plan d'action pour la Méditerranée (PAM).

<https://planbleu.org>

[15] Pausas, J. G., & Keeley, J. E. (2019). Wildfires as an ecosystem service: Let's make them ecological again. *Frontiers in Ecology and the Environment*, 17(10), 529–535.

<https://doi.org/10.1002/fee.2117>

[16] Haut-Commissariat aux Eaux et Forêts (HCEFLCD). (2023). *Rapport sur les incendies dans la province de Chefchaouen – Campagne 2022*. Rabat.

[17] Direction Générale de la Météorologie (DGM). (2022). *Climat de la région Nord – Rapport technique*. Ministère de l'Équipement et de l'Eau, Rabat.

[18] Bouaicha, F., & Boulahfa, I. (2023). Forest Fire Risk Mapping in the Rif Region Using Remote Sensing and GIS Techniques. *Remote Sensing Applications: Society and Environment*, 30, 102918. <https://doi.org/10.1016/j.rsase.2023.102918>.

[19] Climate-Data.org. (2021). *Climat Chefchaouen – Température, précipitations, diagramme climatique*.

<https://fr.climate-data.org/afrique/maroc/chefchaouen/chefchaouen-3997/>

Détection et prédiction des risques d'incendie forestier
dans la province de Chefchaouen à l'aide Du Machine Learning et de la Télédétection